# **Performance Modeling** of Computer Systems and Networks

Prof. Vittoria de Nitto Personè

Operational analysis:

**Queueing Networks** 

Università degli studi di Roma Tor Vergata Department of Civil Engineering and Computer Science Engineering

> Copyright © Vittoria de Nitto Personè, 2021 https://creativecommons.org/licenses/by-nc-nd/4.0/



Da un punto di vista degli analisti di sistema si è creato dello scetticismo, perché il modello era regolamentato da un approccio stazionario, le ipotesi richiedevano indipendenza stocastica tra i job, etc...

> **Analytical models** conceptual model

# **Analytical models**

Queueing network (QN) modelling is a particular approach to computer system (CS) modeling in which the CS is represented as a network of queues which is evaluated analitically

- Many analists experienced doubts on its accuracy
- A series of assumptions:
  - √ the system is modeled by a stationary stochastic process;
  - ✓ jobs are stochastically independent;
  - ✓ job steps from device to device follow a *Markov chain*;
  - √the system is in stochastic equilibrium;
  - √ the service time requirements at each device conform to an exponential distribution;
  - $\checkmark$  the system is  $\emph{ergodic}$ , i.e. long-term time averages converge to the values computed for stochastic equilibrium

Prof. Vittoria de Nitto Personè

Molte assunzioni erano "forzate" rispetto al caso in analisi.

#### Analytical models

# **Analytical models**

Some of these concepts are difficult and cannot be proved to hold by observing the system in a finite time period Most can be disproved empirically

- ✓ parameters change over time
- √jobs are dependent
- ✓ systems are observable only for short periods

**√**..

3

Prof. Vittoria de Nitto Personè

oria de Nitto Personà

# Analytical models

# Analytical models

In applying or validating the results of Markovian QN theory, analists substituted operational values for stochastic parameters

directly measured

4

The Markovian QN equations are also valid among operational variables

They hold under different assumptions and apply to a large class of real systems<sup>1</sup>

BUZEN, J.P. "Operational analysis: the key to the new generation of performance prediction tools," in Proc. IEEE COMPCON, 1976, IEEE, New York.

DENNING, P. J.; AND BUZEN, J. P. "Operational analysis of queueing networks," in Proc. Third Int. Symp. Computer Performance Modeling, Measurement, and Evaluation, 1977, North-Holland Publ. Co., Amsterdam, The Netherlands.

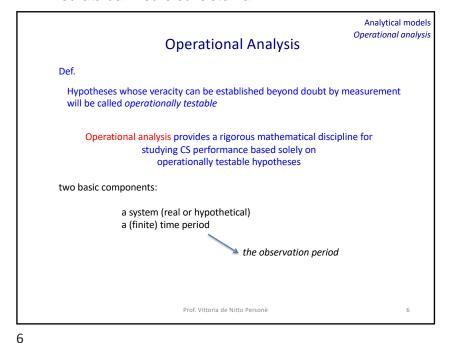
Prof. Vittoria de Nitto Personè

# **Operational Analysis Operational Analysis** Three operational principles: 1. All quantities should be *precisely measurable* and all assumptions should be directly testable 2. The system must be flow balanced 3. The devices must be homogeneous, i.e., the routing must be independent of queue lengths (ql) the mean service time at a given device must not depend on ql of other devices the same mathematical equations but the operational assumptions can be tested much more confidence and understanding of the QN technology

Prof. Vittoria de Nitto Personè

5

Una ipotesi è testabile operazionalmente se può essere misurata da misure sul sistema



Le componenti sono il sistema su cui faccio le misure, e un intervallo di osservazione per il sistema.

Analytical models
Operational analysis

## **Operational Analysis**

According to the operational approach, let us consider

#### Basic quantities

- T the length of the observation period (op)
- A the number of arrivals during op
- B the total amount of time during which the system is busy  $B \le T$  during op
- C the number of completions during op

A/T = frequenza di arrivo, cioè lambda

C/T= frequenza di uscita, cioè X (ma per ora non lo chiamiamo throughput)

B/T= utilizzazione U

B/C= servizio medio S

Prof. Vittoria de Nitto Personè

Osserviamo che: U=C/C \*B/T = C/T \* B/C = X\*S, legge dell'utilizzazione. Non ho fatto nessuna assunzione di equilibrio tra flussi, possiamo infatti derivare l'utilizzazione per una certa finestra, senza bisogno dell'equilibrio. E' valida per ogni finestra temporale. Ma cosa vuol dire bilanciamento dei flussi? Sarebbe A=C, tutto ciò che arriva è uguale a ciò che esce nella stessa finestra temporale T. Essa è una condizione facilmente testabile.

Tale assunzione è detta "job flow balance", allora A/T=C/T, allora lambda = X, ovvero solo sotto condizione di job balance. Allora l'utilizzazione è scrivibile come U = lambda \* S, probabilità che ad un certo istante di tempo il sistema sia occupato.

Non è detto che il JFB valga per ogni finestra temporale, tuttavia si può fare sempre questa assunzione, senza particolari errori. Esso è valutabile con (A-C)/C, se A=C ovviamente ho errore 0, e cresce se A si discosta da C.

## Estensione su più centri

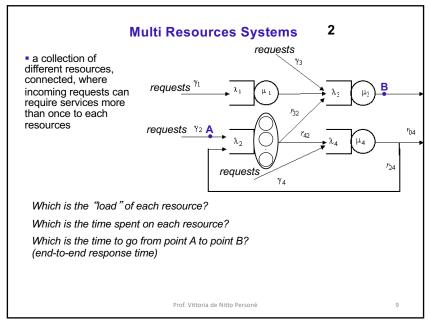
# • a collection of servers, working together for incoming requests • homogeneous servers • homogeneous servers • Data centers Server farm What is the minimum number of servers needed to guarantee that only a small fraction of jobs are delayed? Is a single central queue superior to having a queue at each server?

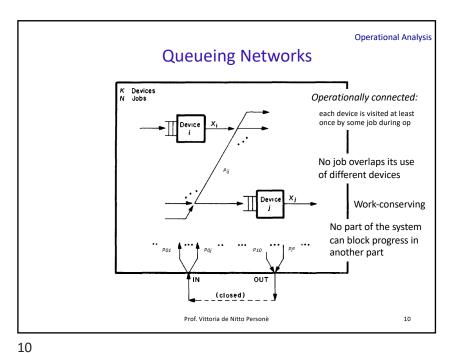
18/05/23

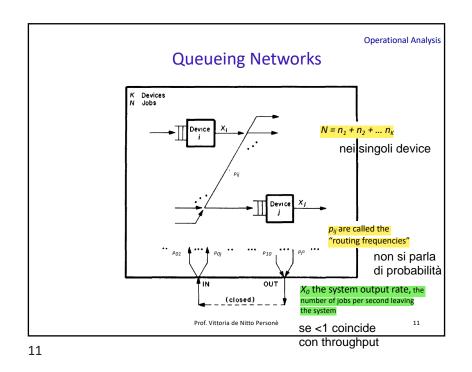
25/05/23

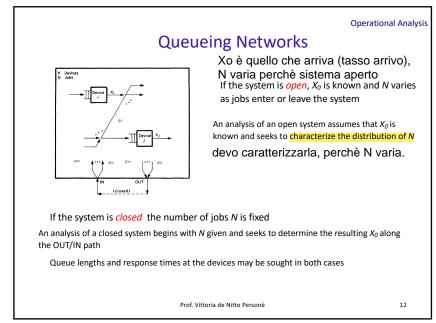
Nel modello operazionale abbiamo la seguente rappresentazione, se il sistema è chiuso dobbiamo scegliere un punto particolare (come un arco). Non deve esserci sovrapposizione di job su devices diversi (no uso simultaneo). I dispositivi sono work conserving, quindi se c'è un job da servire lo si serve (non sta idle). Non c'è blocco, ovvero un dispositivo non può bloccare il progresso di altre parti. C'è sempre posto (equivale al concetto di code infinite, ma questo è uno scenario diverso comunque!)

### modello a code

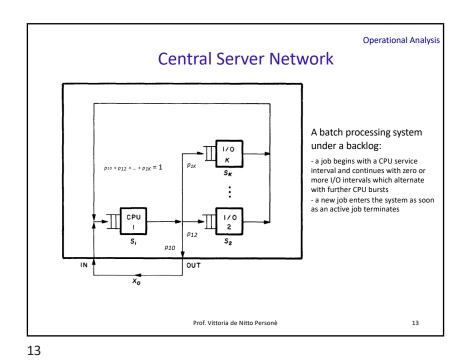


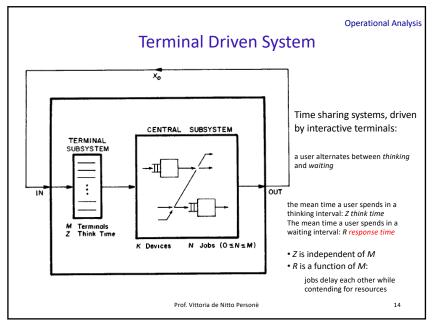






 $^{12}\,\,$  Riprende MVA ricorsivo, anche lui parte da N.





14

Sistema Terminal Driven, c'è un sottosistema che include tutti i terminali (sulla sinistra), e un sistema centrale (sulla destra). M sono i terminali connessi, Z è il tempo in cui l'utente "pensa", da non confondere con il tempo in cui l'utente lancia il comando e rimane in "attesa" della risposta. Il tempo medio in "attesa" corrisponde al tempo medio di passaggio nel "central subsystem", cioè Response Time R. Esso è in funzione di "M", quante più richieste vengono lanciate, più il sistema sarà carico. N varia nel tempo, va da 0 a M (tutti gli utenti aspettano risposta, carico massimo).

# già viste

Operational analysis

## **Queueing Networks**

The system is measured for an op of T seconds, the following data are collected for each device i=1, 2, ...K

 $A_i$  the number of arrivals;

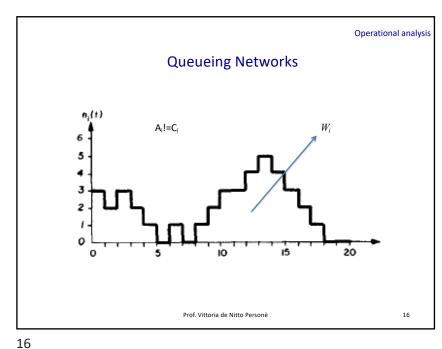
15

- $B_i$  total busy time, during which  $n_i > 0$
- $C_{ij}$  number of times a job requests service at device j immediately after completing a service request at device *i*; note that it is possible  $C_{ii} > 0$ .

If we treat the "outside world" as device "0", we can define also

 $A_{0j}$  number of jobs whose first service request is for device j;  $C_{i0}$  number of jobs whose last service request is for device i.

Prof. Vittoria de Nitto Personè



Operational analysis

17

## **Operational Equations**

 $X_j = \sum_{i=0}^K X_i p_{ij}$ 

passo a loro moltiplicando per Xo ad entrambi

Poer Xo ad entramol

$$\begin{cases} V_0 = 1 \\ V_j = p_{0,j} + \sum_{i=1}^{K} V_i p_{ij} \\ \text{portato fuori (Vo è 1)} \end{cases}$$

Job Flow Balance equations

altrimenti le code crescono, e diventa tutto confusionario.

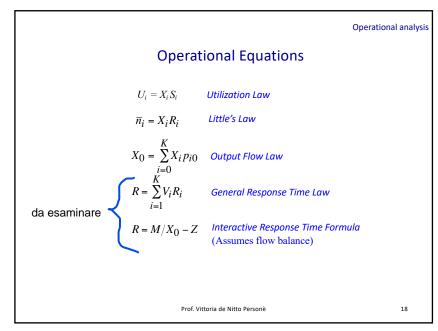
sistema ad unica soluzione Visit Ratio equations

La prima formula viene dai completamenti divisi per il tempo di osservazione.

La legge del flusso forzato è: Xi = Vi Xo, cioè il flusso totale del sistema per il numero medio di visite ci da la parte del singolo Xi.

Prof. Vittoria de Nitto Personè

Se sistema è chiuso, devo scegliere un punto fisso.
V(i/j) = Yi/Yj quante volte in media visito "i" per un passaggio a "j".



legge generale del tempo di risposta ritrovata operazionalmente

Rmedio = Nmedio/Xo = sum da i=1 a k di (n(i))/Xo, perchè N medio = n1 medio + n2 medio +.... se applico Little: sum da i=1 a k di Ri [Xi / Xo], = sum da i=1 a k di Ri [Vi]

Per il sistema INTERATTIVO



il tempo (Z + R)Xo = M per Little, applicato a tutto.

L'interactive response time, per un sistema di questo tipo è: R = M/Xo - Z, dalla formula precedente.

Questo sistema serve una parte di carico "aperta", e poi c'è un insieme di terminali fissati. C'è il carico interattivo (lancio richiesta - aspetto risposte) e carico batch.

