



18/01/2023

Tolleranza ai Guasti nei Sistemi Distribuiti

Corso di Sistemi Distribuiti e Cloud Computing
A.A. 2021/22

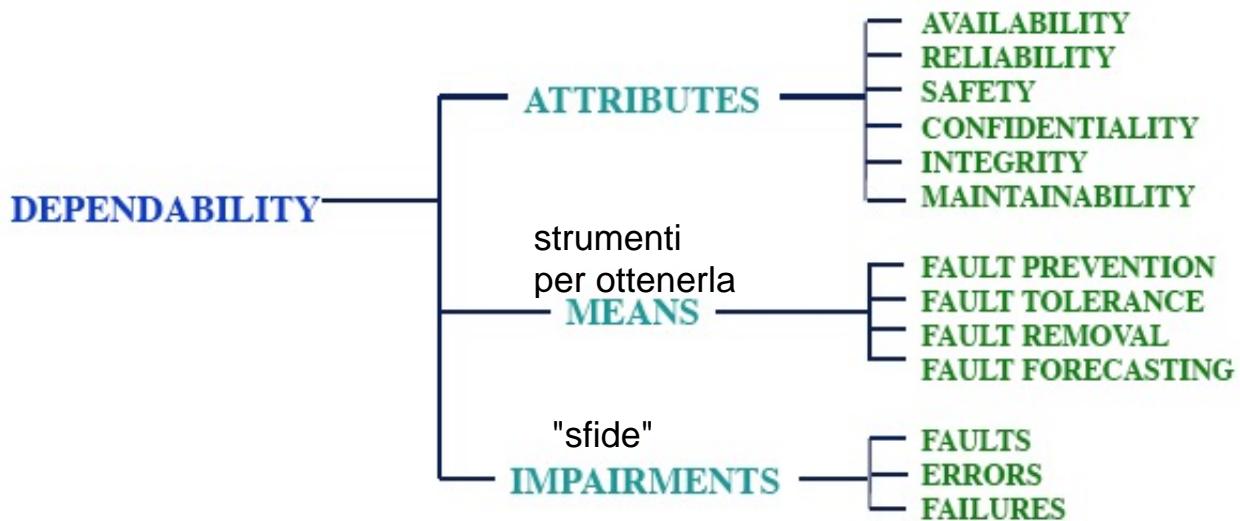
Valeria Cardellini

Laurea Magistrale in Ingegneria Informatica

Dependability

- Per comprendere il concetto di tolleranza ai guasti, analizziamo la definizione di **dependability**
 - Abilità di un sistema di fornire un servizio che può essere considerato fidato in maniera giustificata (“*The trustworthiness of a computing system which allows reliance to be justifiably placed on the service it delivers.*”, IFIP WG 10.4)
 - Abilità di un sistema di evitare interruzioni di servizio più frequenti ed importanti di quanto accettabile
- Un *componente* di un sistema può **dipendere** da altri componenti del sistema
 - Un componente C fornisce *servizi* ai suoi clienti; per fornire tali servizi C può richiedere servizi ad un altro componente C*
 - C dipende da C* se la correttezza del comportamento di C dipende dalla correttezza del comportamento di C*
 - Componente = *processo* o *canale di comunicazione*

Dependability: taxonomy



Dependability: attributi

- Proprietà di un sistema **dependable**
 - Disponibilità
 - Affidabilità
 - Safety
 - Manutenibilità
 - Integrità

Dependability: disponibilità

- **Disponibilità (availability)** posso usare il sistema? il sistema è pronto?
Can I use the system now? Non mi dice se l'operazione che richiedo verrà completata o meno.
- Sistema pronto (operativo) per essere usato
 - Probabilità in funzione del tempo che il sistema sia correttamente operativo all'istante t
- Proprietà di sistema, definita come
$$A = \text{MTTF}/(\text{MTTF} + \text{MTTR})$$
 - MTTF = Mean Time To Failure tempo medio tra due fallimenti
 - MTTR = Mean Time To Repair
 - MTTF + MTTR = MTBF = Mean Time Between Failure
- Si misura usualmente con la scala dei 9
 - A = 99%: two nines downtime per year = $0.01 * 365.2425$ d = 3d 15h 39m 29.5s
 - A = 99.99%: four nines 0,001 s downtime per year = 52 m 35.7 s

tempo medio per rendere operativo sistema di nuovo attivo post fallimento

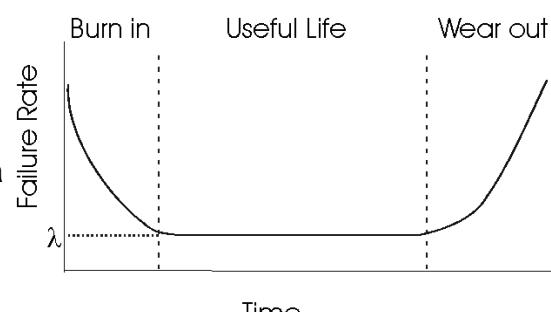
Valeria Cardellini - SDCC 2021/22

4

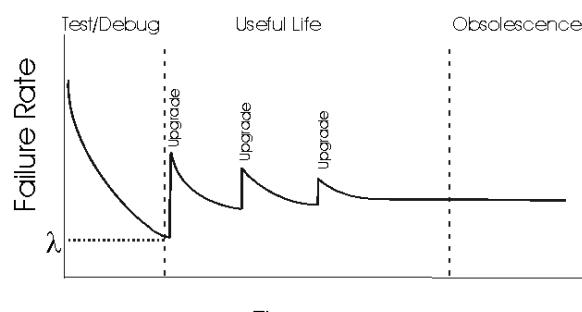
Dependability: affidabilità

- **Affidabilità (reliability)** Will the system be up as long as I need it?
 - Sistema funzionante senza guasti in maniera continuativa il sistema sarà online per il tempo che ho bisogno?
 - Probabilità condizionale che il sistema sia correttamente funzionante in $[0, t]$ se il sistema stesso era funzionante all'istante 0
 - Metrica: MTTF
 - Tasso di fallimento (failure rate)

Bathtub curve for hardware reliability



Revised bathtub curve for software reliability



Valeria Cardellini - SDCC 2021/22

5

Availability vs reliability

- **Disponibilità ≠ affidabilità!**
- Es. 1: sistema non funzionante per 1 ms ogni ora
 - Disponibilità elevata > 99,9999% ($= 1 - 1/(3600*1000)$)
 - Ma affidabilità bassa, essendo MTBF = 1 ora ed essendoci $24*365=8780$ failure all'anno
- Es. 2: sistema che non smette mai di funzionare ma spento per 2 settimane l'anno
 - Disponibilità pari a 96% ($= 1 - 14/365$)
 - Ma altamente affidabile

Dependability: attributi

- **Safety** se si rompe, quali sono le conseguenze?
If the system fails, what are the consequences?
 - Se il sistema smette di operare correttamente, non succede nulla di catastrofico per l'utente e l'ambiente
 - Probabilità che il sistema non mostri malfunzionamenti nell'istante in cui gli è richiesto di operare, oppure che, anche se esso mostra un malfunzionamento, questo non comprometta la sicurezza di persone o impianti relazionati al sistema stesso.
- **Manutenibilità (maintainability)**
How easy is the system to fix if it breaks? quanto è facile fixarlo?
 - Misura la facilità con cui il sistema può essere riparato dopo un guasto
 - Metrica: MTTR
- **Integrità (integrity)**
 - Assenza di alterazioni improprie del sistema

Failure, error e fault

- **Failure (fallimento)**: si verifica quando il comportamento di un componente del sistema non è conforme alle sue specifiche
 - Es: crash del programma
- **Error (errore)**: stato interno non corretto del componente che può determinare un failure
 - E' una deviazione dello stato del componente dai possibili stati previsti
 - Bug di programmazione
- **Fault (guasto)**: la causa di un errore
 - Guasti transienti, intermittenti o permanenti
 - Es: programmatore distratto

fault → error → failure

Dependability: strumenti

- **Prevenzione di guasti**
 - Prevenire l'occorrenza dei guasti, ad es. migliorando la progettazione
- **Tolleranza ai guasti (fault tolerance)** 
 - Il sistema continua a funzionare in modo conforme alle sue specifiche (non subisce un fallimento) anche in presenza di guasti in qualche componente
 - In un sistema fault-tolerant i guasti vengono mascherati
 - Possibile degrado delle prestazioni del sistema: occorre trovare adeguate ottimizzazioni e compromessi come replicazione.
- **Rimozione di guasti**
 - Ridurre la presenza, il numero, la serietà dei guasti
- **Predizione di guasti**
 - Stimare l'incidenza futura e le conseguenze dei guasti

Tipi di failure

- In che modo possono fallire i componenti di un SD?
- Diversi tipi di failure:
 - Crash: il componente si arresta, ma aveva funzionato correttamente fino a quel momento
 - Omissione: il componente non risponde ad una richiesta
 - Fallimento nella temporizzazione: il componente risponde ma il tempo di risposta supera l'intervallo specificato
 - Fallimento nella risposta: la risposta del componente non è corretta
 - Fallimento nel valore
 - Fallimento nella transizione di stato
 - Fallimento arbitrario (o *bizantino*): il componente può produrre una risposta arbitraria con tempi arbitrari
 - Guasto bizantino: sintomi diversi ad osservatori diversi
- I crash sono i fallimenti più innocui, quelli bizantini i più gravi

Modelli di failure

- *Problema nei SD*: distinguere tra componente che ha subito un crash ed uno che è solo troppo lento
 - Esempio: il processo P attende dal processo Q una risposta, che tarda ad arrivare posso mettere timeout, ma devo trovarlo adeguato.
 - Q è soggetto ad un fallimento nella temporizzazione o ad una omissione?
 - Il canale di comunicazione tra P e Q è soggetto ad un guasto?
- Modelli di failure: dal meno al più grave
 - Fallimento **fail-stop**: Q ha subito un crash e P può scoprire il fallimento (tramite timeout o preannuncio)
 - Fallimento **fail-silent**: Q ha subito un crash o un'omissione, ma P non può distinguerli
 - Fallimento **fail-safe**: Q ha subito un fallimento arbitrario, ma senza conseguenze
 - Fallimento **fail-arbitrary**: Q ha subito un fallimento arbitrario non osservabile

Rilevare i fallimenti

- Per mascherare i fallimenti, bisogna innanzitutto rilevarli
- **Failure detection** per rilevare il fallimento di un processo
 1. *Attiva*: invio di un messaggio e **timeout** per rilevare se un processo è fallito
 - Soluzione più usata, adatta per fallimento fail-stop
 2. *Passiva*: attesa di ricevere un messaggio
 3. *Proattiva*: come effetto collaterale dello scambio di informazioni tra vicini (ad es. disseminazione delle informazioni basata su gossiping)
- Difficoltà con timeout
 - Come impostare il valore del timeout? Ok nei **SD sincroni**, ma in quelli asincroni?
 - Inoltre, timeout dipende anche dall'applicazione
 - Come distinguere tra fallimenti dei processi o della rete?

Practical failure detection

- How can we **reliably detect** that a process has **actually crashed**?
- General model
 - Each process is equipped with a failure detection module
 - A process P probes another process Q for a reaction
 - If Q reacts: Q is considered to be alive (by P)
 - If Q does not react within t time units: Q is **suspected** to have crashed (if the system is synchronous: suspected = sure)
- Practical implementation
 - If P did not receive heartbeat from Q within timeout t : P **suspects** Q
 - If Q later sends a message (which is received by P):
 - P stops suspecting Q
 - P increases t
 - Note: if Q did crash, P will keep suspecting Q

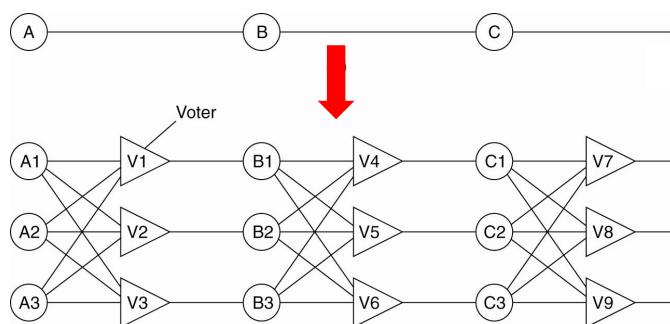
Ridondanza

- Tecnica principale per mascherare i guasti
- Tipologie di ridondanza
 - Ridondanza *delle informazioni*
 - Ad es.: codice di Hamming, bit di parità , aumento overhead
 - Ridondanza *nel tempo* (ricarico la pagina)
 - Viene eseguita un'azione e, se necessario, viene rieseguita
 - Utile per guasti transienti o intermittenti
 - Ridondanza *fisica*
 - Si aggiungono attrezzature o processi extra
 - A livello hardware o software
 - Esempio: ridondanza modulare tripla

ogni componente
replicato 3 volte

Ridondanza modulare tripla

- Esempio di ridondanza fisica: **Triple Modular Redundancy** (TMR, ridondanza a 3 moduli)
 - 3 componenti replicati eseguono un'operazione, il cui risultato viene sottoposto ad una votazione per produrre un unico output
 - Se uno dei tre componenti replicati fallisce (singolo fallimento di tipo arbitrario), gli altri due possono mascherare e correggere il guasto



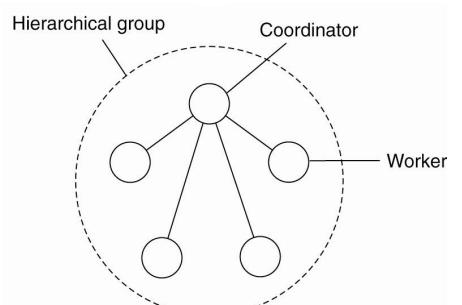
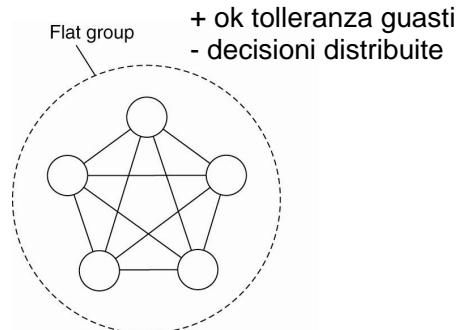
Perché 3 voter e non uno solo?
Anche i voter possono rompersi.

Resilienza dei processi

- In ingegneria: **resilienza** = capacità di un materiale di resistere a forze di rottura
- Nei SD: capacità del SD di fornire e mantenere un livello di servizio accettabile in presenza di guasti e minacce alla normale operatività
- Come mascherare in un SD il guasto di un processo?
Replicando e distribuendo la computazione in un gruppo di processi identici

Resilienza dei processi

- **Gruppo flat**
 - Adatto per tollerare guasti (simmetria e assenza di single point of failure)
 - Maggiore overhead perchè il controllo è completamente distribuito (più difficile da implementare)
- **Gruppo gerarchico**
 - Singolo coordinatore
 - Tollerante ai guasti?
 - Relativamente semplice da implementare



Modelli di replicazione: passiva vs. attiva

- Due modelli alternativi
 - Replicazione passiva
 - Replicazione attiva
- Replicazione **passiva**
 - Gruppo di processi organizzati in modo **gerarchico**
 - Una sola replica primaria esegue le azioni sui dati; le altre repliche (passive) servono in caso di guasto
 - Una sola replica corretta, le altre possono anche non essere aggiornate (repliche calde o fredde)
 - Possibile scollamento dello stato tra replica primaria e repliche secondarie
 - **Checkpoint** per tenere aggiornare lo stato delle repliche secondarie
 - Se la replica primaria subisce un crash, le altre repliche eseguono un algoritmo di elezione per individuare il nuovo coordinatore
 - Esempio: protocolli **primary-based** per la consistenza

Modelli di replicazione: passiva vs. attiva

- Replicazione **attiva**
 - Gruppo di processi organizzati in modo **flat**
 - Coordinamento tra repliche attive
 - Costo di coordinamento: aumenta con la scala del sistema e la complessità delle politiche di coordinamento
 - Esempio: protocolli replicated-write per la consistenza

scrivo su tutte le repliche, o su un sottoinsieme di repliche. Poichè possono esserci scritture concorrenti devo far eseguire le scritture nello "stesso ordine". Serve protocollo di consenso per far mettere d'accordo le repliche, per decidere quale sia l'ordine delle operazioni che devono essere effettuate.

Gruppi e mascheramento dei guasti

- Consideriamo un gruppo **flat**
- Un gruppo composto da N processi è **k -fault tolerant** se **può mascherare k guasti concorrenti** $k < N$
 - k è detto **grado di tolleranza ai guasti**
- Quanto deve essere grande un gruppo k -fault tolerant?
 - **Dipende** dal modello di failure

Per tollerare fault più complessi devo aumentare grado di replicazione nel sistema.

Gruppi e mascheramento dei guasti

- Quanto deve essere grande un gruppo k -fault tolerant?
 - Fallimento **fail-stop** o **fail-silent** → $N \geq k+1$ processi
 - Nessun processo del gruppo produrrà un risultato errato, quindi **il risultato di un solo processo non guasto è sufficiente**
 - Fallimento **arbitrario** è il risultato del gruppo è definito tramite un **meccanismo di voto** → $N \geq 2k+1$ processi
(generalizzazione di TMR)
 - Abbiamo bisogno di $2k+1$ processi non guasti in modo che il risultato corretto possa essere ottenuto con un voto a maggioranza
- **Assunzioni importanti:**
 1. I processi sono **identici**
 2. I processi eseguono i comandi nello stesso ordine
 - Per essere certi che tutti i processi facciano esattamente la stessa cosa quindi serve consenso, per essere d'accordo sull'azione successiva da eseguire.

Consenso nei sistemi distribuiti

- **Assunzione:** consideriamo ora che i processi del gruppo **non siano identici**, ovvero che ci sia una **computazione distribuita**
- **Obiettivo:** i processi non guasti del gruppo devono raggiungere un **consenso (accordo)** unanime su uno stesso valore (es. il prossimo comando da eseguire) in un numero finito di passi, nonostante la presenza di processi guasti
 - Esempi di consenso: elezione di un coordinatore, mutua esclusione, commit di una transazione
- **Che tipo di guasti?**
 - Guasti non bizantini (es. crash, omissioni)
 - Guasti bizantini
"Generali bizantini", è un algoritmo di Lamport, richiede che sistema sia sincrono + altre ipotesi.

algoritmi Paxos e Raft
per crash/omissioni, no bizantini.
Funziona anche in contesti asincroni.

Consensus = agreement?

- In the course we treat these terms as synonyms
- But for the theoretical DS community the two terms refer to very similar but not identical problems
 - **Agreement problem:** a single process has the initial value
 - **Consensus problem:** all processes have an initial value
- We'll examine in details three consensus algorithms
 1. **Paxos** - elegante ma di difficile implementazione.
 2. **Raft** - più "pratico"
 3. **Byzantine generals**
 - The first two are consensus problems, the last is an agreement problem (see the original algorithm by Lamport)
- Let us first examine the necessary conditions for consensus and the FLP impossibility result

Consenso distribuito: quando può essere raggiunto

- Consideriamo le diverse tipologie di:
 - processi
 - ritardi di comunicazione
 - ordinamento dei messaggi
 - trasmissione dei messaggi
- Processi: *sincroni* o *asincroni*?
 - Processi sincroni: operano in modalità *lock-step*, ovvero esiste $c \geq 1$ tale che se un processo ha eseguito $c+1$ passi, ogni altro processo ha eseguito almeno 1 passo
- Ritardo nella comunicazione: *limitato* o *illimitato*?
- Ordinamento dei messaggi: messaggi consegnati nello stesso *ordine* in cui sono stati inviati oppure *senza ordine*?
- Trasmissione dei messaggi: *unicast* o *multicast*?

Valeria Cardellini - SDCC 2021/22

24

Consenso distribuito: quando può essere raggiunto

- Quali sono le *condizioni necessarie* per poter raggiungere il consenso in un SD soggetto a guasti?

		Message ordering				Communication delay
		Unordered		Ordered		
Process behavior	Message transmission	Synchronous	X	X	X	X
					X	X
Asynchronous	Message transmission				X	
						X

Sistema sincrono: caso più facile.

prima riga: sincrono + bounded (ritardi finiti): riesco in tutto.

seconda riga: sincrono + non bounded: riesco se msg sono ordinati.

Valeria Cardellini - SDCC 2021/22

25

FLP impossibility result

- FLP impossibility result:

Fischer, Lynch and Patterson, “Impossibility of distributed consensus with one faulty process”, 1985

- In an **asynchronous** model with an **unbounded but finite message delay**, where **only one processor might crash**, there is **no distributed algorithm** that solves the consensus problem
- They prove that no asynchronous algorithm for agreeing on a one-bit value can guarantee that it **will terminate** in the presence of crash faults
 - And this is true even if no crash actually occurs!
- The good news: **impossibility means “is not always possible”**
 - FLP proves that any fault-tolerant algorithm solving consensus has runs that never terminate, but these runs are **extremely unlikely** (“probability zero”)

FLP impossibility result

- What makes consensus hard? **Membership** in an **asynchronous environment**:
 - 1) we can't detect failures reliably because process speeds and channel delays are not bounded
 - 2) a faulty process stops sending messages but a “slow” message might confuse us
- Are distributed and Cloud systems asynchronous?
 - Not in the sense of the definition used in the FLP result, where asynchronous systems have no common clocks and make no use of time, and networks never lose messages but can delay them arbitrarily long
 - **In practice** we have **partially synchronous systems**: most of the time, we can assume the system to be synchronous, yet there is no bound on the time that a system is asynchronous
 - Normally, we can reliably **detect crash failures** (see slide 13)

algoritmo di consenso distribuito tollerante ai guasti, eseguito da N processi facenti parte del sistema, che permetta di tollerare fino a k guasti concorrenti, con N processi $\geq 2k+1$ (quorum), il sistema è asincrono. E' il primo protocollo proposto, ed è elegante. In realtà identifichiamo una famiglia di protocolli di Paxos (troviamo ad esempio anche la variante tollerante ai guasti bizantini).

PAXOS

- A fault-tolerant consensus protocol run by N processes to tolerate up to k failures (where $N \geq 2k+1$) in an asynchronous system
- Important and widely studied/used protocol
 - Perhaps the most important consensus protocol
 - The dominant offering for **consensus in asynchronous systems**
- Rather a family of consensus protocols
 - Cheap Paxos, fast Paxos, generalized Paxos, byzantine Paxos, ...
- We will study the **basic version**:
L. Lamport, "[Paxos made simple](#)", ACM SIGACT News, Vol. 32, No. 4, Dec. 2001.

The history of Paxos

- Elegant and relatively simple algorithm
 - but “the original presentation was Greek to many readers” because presented through the allegory of a fictitious ancient Greek parliamentary government on the island of Paxos
- See the original paper [The part-time parliament](#)
 - “Inspired by my success at popularizing the consensus problem by describing it with Byzantine generals, I decided to cast the algorithm in terms of a parliament on an ancient Greek island.”
 - “To carry the image further, I gave a few lectures in the persona of an Indiana-Jones-style archaeologist.”
 - “My attempt at inserting some humor into the subject was a dismal failure. People who attended my lecture remembered Indiana Jones, but not the algorithm. People reading the paper apparently got so distracted by the Greek parable that they didn’t understand the algorithm.” (L. Lamport)
- “The Paxos algorithm, when presented in plain English, is very simple.” (L. Lamport)

Paxos: distributed system model

Assumptions (rather weak and realistic)

- Partially synchronous system (it may even be **asynchronous**) with **non-arbitrary** failures per alcuni tempi è asincrono, guasti arbitrati (esclusi bizantini).
- Processes communicate with one another by **sending messages**
- Communication between processes may be **unreliable**, indeed messages:
 - Take arbitrarily long to be delivered
 - May be duplicated or lost
 - Corrupted messages can be detected and thus subsequently ignored

posso avere msg persi, duplicati, consegnati in ritardo.
Se msg corrotto == bizantino assumo di poterli identificare e ignorarli.

Paxos: distributed system model

Assumptions (rather weak and realistic)

- Processes:
 - Set of processes that run Paxos is known a-priori so chi esegue Paxos.
 - Operate at arbitrary speed velocità variabile, in quanto arbitrari.
 - Are **fail-stop: may exhibit crash failures but not arbitrary failures**
 - Can be restarted and rejoin if they fail rifanno parte dell'esecuzione del consenso.
 - Can remember some information if restarted after failure (accessing a persistent storage that survives crashes)
 - Do not collude (i.e., do not team up to produce a wrong result)
processi "non barano", non si mettono d'accordo per produrre un risultato sbagliato.

Paxos: a quorum-based protocol

- Problem: get a set of processes to reach consensus on a **single proposed value**
 - no value proposed → no value chosen
 - value chosen → processes should **learn** the chosen value

- Main idea: a **quorum-based protocol**
 - Proposals are associated with a **unique sequence number**
 - Processes vote on each proposal
 - A proposal approved by a **majority** will get passed
 - Size of majority is “well known” because potential membership of system was known a-priori
 - A process considering **two proposals** approves the one **with the larger version number**

Paxos requirements

- **Safety requirements** Requisiti di safety
 - Only a value that has been proposed may be chosen solo un valore scelto.
 - Only a single value is chosen
 - A process never learns that a value has been chosen unless it really *has* been chosen

- Don’t care *what value is chosen, just as long as it satisfies those three requirements*

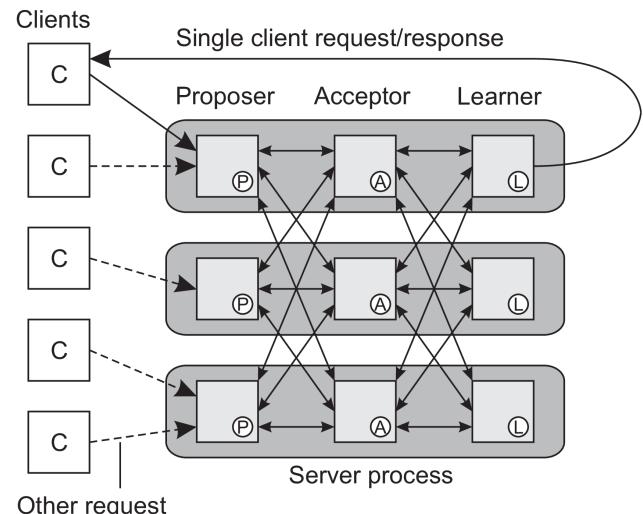
- **Liveness requirements** - "deve succedere qualcosa di buono".
 - Some proposed value is eventually chosen
 - If a value has been chosen, a process can learn the value

Paxos compromise

- Remember FLP impossibility result
 - No asynchronous consensus algorithm can guarantee both liveness and safety
- However, asynchrony of FLP is *overly pessimistic*
- Real systems are usually *partially synchronous*
 - Behavior close to synchronous “most of the time”
 - Sometimes go asynchronous
- Practical compromise
 - Compromise liveness when the system behaves asynchronously
 - But never safety
- Therefore
 - Paxos **does not guarantee liveness**
 - Might never terminate, but in practice it does terminate

Paxos roles

- A process may play three different roles:
 - *Proposer, acceptor, learner*
- **Proposers** propose a value to be chosen on behalf of clients Propone valore per il consenso, lo fa per conto dei clienti.
- **Acceptors** (i.e., voters) decide which value to choose
- Learners *learn which value was chosen* and *report the final decision back to clients*
- Processes can play one, two, or all three roles
 - Thinking of these roles as being separate makes Paxos easier to understand



Paxos: some ideas

1. One acceptor makes things really easy:
 - But this isn't distributed at all: if acceptor fails, game over!
 - So, let us have **multiple acceptors**, each of which can accept a proposed value
2. A value is chosen once a **simple majority** of acceptors accepts it
 - If m acceptors, then $> m/2$ need to accept
 - Why does this work?
 - Any two majorities of acceptors must have at least one acceptor in common
 - An acceptor can accept only one value at a time
 - Therefore, any two majorities that choose a value must choose the same value
 - Just need to make sure acceptors do not accept something else once a value is chosen

se ho due gruppi, un accentante è in comune. Un acceptor accetta un valore alla volta.

Paxos: some ideas

3. Acceptors need a way to distinguish one proposal from another
 - Proposers assign a **unique sequence number** to each proposal they make
 - A **proposal** has two parts:
 - A **proposal number** (i.e., the unique identifier)
 - The **proposed value** (could be a decision value or some other information, such as "Frank's new salary" or "Position of Air France flight 21")
 - Note that there can be *multiple distinct* proposals for the same value
 - But they differ for the identifier

Ho più client, che contattano proposer differenti, posso avere differenti proposte, anche uguali, ma differiscono per il numero di sequenza univoco.
4. Stable storage, preserved during failures, used to maintain the information that must be remembered in case of failure

Molteplici iterazioni. Paxos è distribuito.

I proposer non comunicano tra loro, gli acceptor non comunicano tra loro, ovvero non ho comunicazioni tra stessi ruoli.

Voglio consenso su stesso valore, quindi se proposer ha proposta accettata, gli altri proposer 'convergono' a quella proposta, per questo ho molteplici round. Proposer propongono in modo concorrente, ma consenso è unico valore.

Paxos: some ideas

5. Paxos use a **multiple-round** approach

- Once a decision on a value is reached in a round, decisions in all subsequent rounds must agree
 - Once decision is reached on a value, Paxos must force future proposers to select that same value (see slide 46)
- *Within each round, finding consensus is a **two-phase** process, where each phase consists of:*
 - a request sent from a proposer to a group of acceptor
 - a reply from the acceptors to the proposer
- The two phases are:
 - 1) **Prepare** : Proposer con valore inviano richiesta a gruppo di acceptor.
 - 2) **Accept** Risposta dagli acceptor ai proposer.

Paxos: the two phases

- At a high level:

1) **Prepare**

- A proposer asks a majority of acceptors whether anyone already received a proposal
- If the answer is no, propose a value

2) **Accept**

- If a majority of acceptors agree to this value, then that is our consensus

- Goals of the two phases:

Prepare Controllano se c'è già valore di proposta scelto, nel round precedente.

- Proposers check whether a value has already been chosen
Vecchie proposte non completate vengono bloccate.
- Older proposals that have not yet completed are blocked

Accept

- Ask acceptors to accept a specific value

Paxos algorithm: phase 1

- Phase 1 (**prepare**):
 - a) A proposer selects a proposal number n and sends a **prepare request** with number n to a majority of acceptors
Proposer sceglie proposta n° "n" e manda prepare request "n" a un gruppo di maggioranza di acceptors.
 - b) If an acceptor receives a prepare request with number n :
 - If n is greater than the proposal number of **any** prepare request the acceptor has responded to, the acceptor **promises** not to accept any lower-numbered proposals **and replies with the highest-numbered proposal and the proposed value the acceptor has accepted, if any**
 - Otherwise the acceptor does not respond (or responds with a negative ack)

L'accept riceve la prepare, riceve richiesta con n° sequenza "n":

- Se $n >$ numeri di sequenza precedenti, l'accept "promette" di rifiutare altre richieste con "n" minori, e risponde con $< n^{\circ} \text{sequenza}, \text{valore proposto} >$ (quelli mandati dal proposer).
- Altrimenti non risponde, o risponde con un "not ack".

Valeria Cardellini - SDCC 2021/22

40

L'accept appartiene allo stesso round.

a) Proposer riceve richieste da maggioranza acceptor a cui aveva inviato, sceglie il valore da mandare. Prende tra le risposte ricevute, quella con numero sequenza maggiore e valore associato, che proporrà. Se 1° round, non c'è valore già noto, e quindi userà valore casuale dei clienti.

Paxos algorithm: phase 2

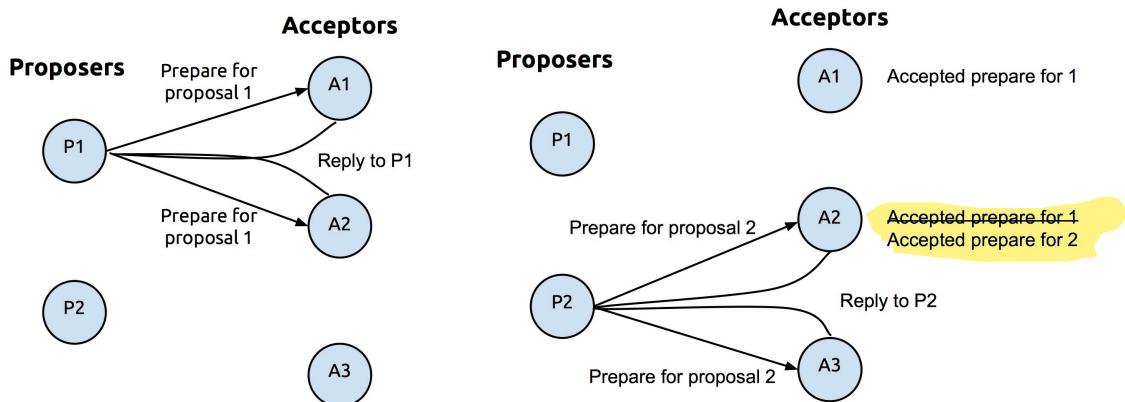
- Phase 2 (**accept**):
 - a) If the proposer receives a response to its prepare requests for the proposal numbered n **from a majority of acceptors**, it sends an **accept request** to each of those acceptors for a proposal numbered n **with a value v which is the value of the highest-numbered proposal among the responses of phase 1** (if no acceptor had accepted a proposal up to this point, then the proposer may choose any value for its proposal)
 - b) If an acceptor receives an accept request for n , it accepts the proposal unless it has already responded to a prepare request having a number greater than n
- Definition of chosen
 - **A value is chosen at proposal number n iff majority of acceptors accept that value in phase 2 of the proposal number**

Paxos properties

- Any proposal number is unique
- Any two sets of acceptors have at least one acceptor in common
- The value sent out in the accept phase is the value of the highest-numbered proposal of all the responses received in the prepare phase

Paxos: example (without failures)

- Proposers are p_1 and p_2
 - Acceptors are a_1 , a_2 , and a_3
- Proposer deve contattare 2 acceptor (che sono 3 totali, quindi maggioranza stretta).
 p_1 e p_2 mandano "richiesta prepare" agli acceptor, che hanno A_2 in comune, con numero sequenza "1" e "2" univoca.
- 1° round, prepare phase**
- p_1 sends prepare request for proposal 1 to a_1 and a_2
 - a_1 and a_2 reply to p_1
 - p_2 sends prepare request for proposal 2 to a_2 and a_3
 - a_2 and a_3 reply to p_2

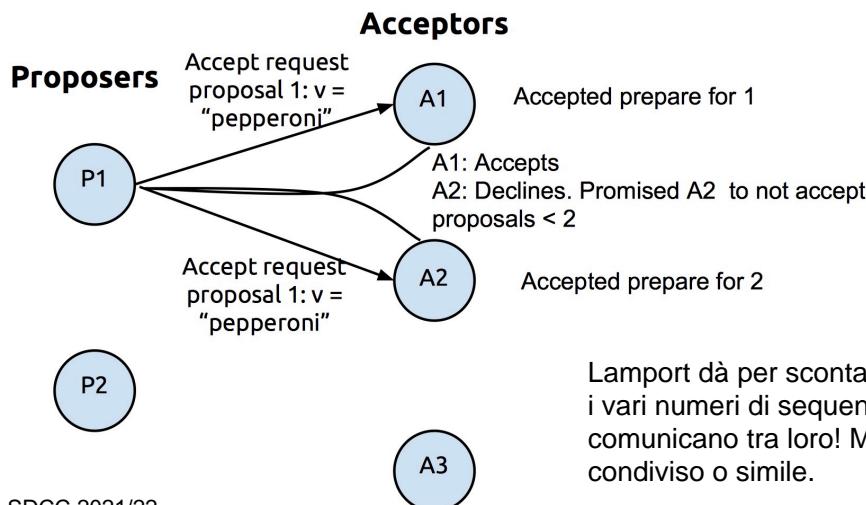


P1 manda richiesta di accept con numero richiesta "1", e valore "pepperoni". A1 accetta, A2 declina, perchè lei accetta proposte con numeri di sequenza >2. P1 non ha maggioranza di risposte positive.

Paxos: example (without failures)

1° round, accept phase

- p₁ sends accept request to a₁ and a₂ for proposal 1 with value "pepperoni"
 - p₁ got to select which value to propose
- a₁ accepts proposal 1
- a₂ does not accept proposal 1 (the older proposal is blocked)
 - a₂ promised p₂ it would not accept proposals < 2



Valeria Cardellini - SDCC 2021/22

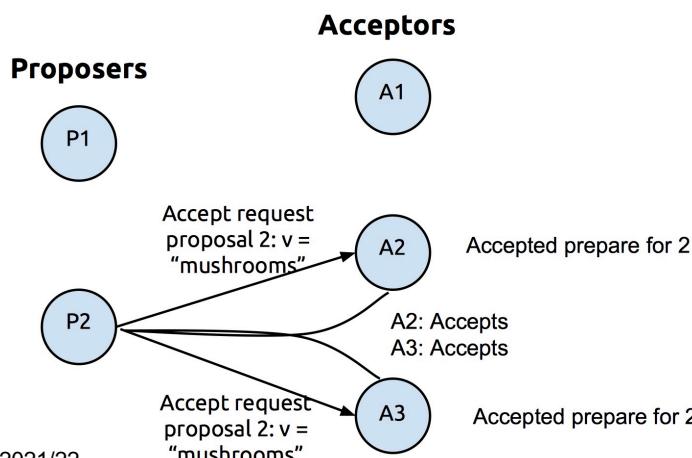
44

P2 manda accept con n°"2" e valore "mushroom", entrambi rispondono positivamente, poichè sequenza è la più alta. Valore scelto è "Mushroom".

Paxos: example (without failures)

1° round, accept phase (continued)

- p₂ sends accept request to a₂ and a₃ for proposal 2 with value "mushrooms"
 - p₂ also got to select which value to propose
- a₂ accepts proposal 2
- a₃ accepts proposal 2
- {a₂, a₃} is a majority of acceptors, so proposal 2 is chosen
 - The chosen value is "mushrooms"



Valeria Cardellini - SDCC 2021/22

45

A1 risponde che prima aveva accettato "pepperoni", mentre A2 "mushroom".

Nell'accept P1 manda richiesta ad A1 e A2 per proposta "3" con valore "Mushroom", che è il valore della proposta 2 (perchè ciò ci viene garantito dal funzionamento dell'algoritmo.)

Paxos: example (without failures)

2° round, prepare phase

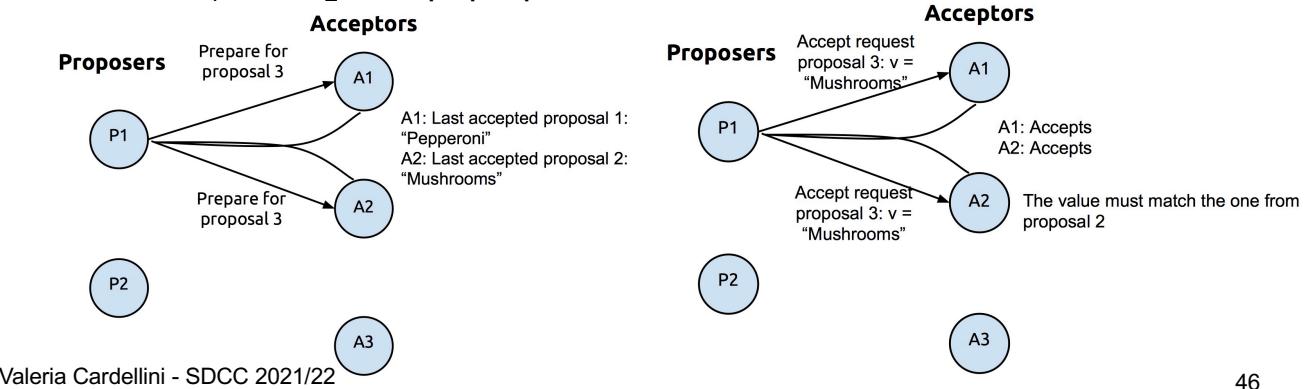
- p₁ sends prepare request for proposal 3 to a₁ and a₂
- a₁ replies; it last accepted proposal 1 for “pepperoni”
- a₂ replies; it last accepted proposal 2 for “mushrooms”

E' nuovo round, quindi n° "3"

2° round, accept phase

- p₁ sends accept request to a₁ and a₂ for proposal 3 with value “mushrooms”
 - Value must match the one from proposal 2
- a₁ and a₂ accept proposal 3

Quando P1 manda prepare ad A1 e A2, questi gli dicono che hanno accettato richieste "1" e "2", P1 allora chiederà di accettare la "2", poichè con id più alto.



Valeria Cardellini - SDCC 2021/22

46

Paxos: what about learners?

- There are some options to learn a chosen value:
 - Each acceptor, whenever it accepts a proposal, informs all the learners
 - ✗ Lots of messages to be sent
 - Acceptors inform a distinguished learner (usually the proposer) and let the distinguished learner broadcast the result
 - ✗ Single point of failure
 - Compromise with a set of distinguished learners?
 - ✓ Limits number of messages needed
 - ✓ All distinguished learners need to fail to cause a problem

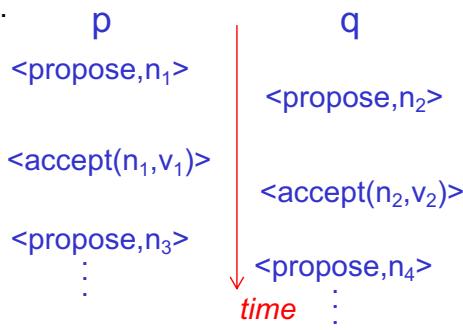
Avevamo detto che esistono run che non terminano mai. Esso è il run in cui i proposer che "duellano" tra loro e che propongono valori differenti ad ogni round senza che si arrivi mai alla terminazione.

Paxos: distinguished proposer (or leader)

- Multiple dueling proposers that propose conflicting values may stall the protocol (because of FLP result)

spiegazione nel

"Puntino" qua sopra.



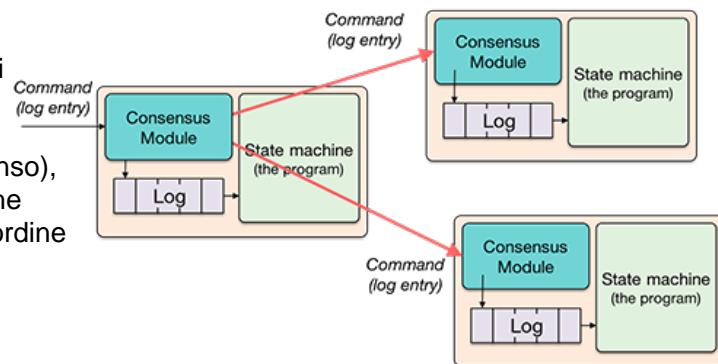
p completes phase 1 for proposal number n_1 . Another proposer q then completes phase 1 for proposal number $n_2 > n_1$. p's phase 2 accept requests for proposal numbered n_1 are ignored because at least one acceptor has promised not to accept any new proposal numbered less than n_2 . So, p then begins and completes phase 1 for new proposal number $n_3 > n_2$, causing the second phase 2 accept requests of q to be ignored. And so on.

- Paxos guarantees progress (i.e., liveness) if only one of the proposers is eventually chosen as **leader**
- Therefore, in many Paxos implementations there is **only one active proposer** (i.e., leader)
 - Other proposers send proposals only when the current leader fails, and a new one needs to be elected

State machine replication and consensus protocols

Ho 3 repliche del servizio.

Ognuna ha una macchina a stati (programma eseguito), un log (lista di comandi), e il modulo di consenso (alg. consenso), avente l'obiettivo di avere repliche allineanti, mantenendo stesso ordine del log



- State machine replication (SMR): general approach to build fault-tolerant systems based on replicated servers
 - Each replica has a **state machine** and we want to make it fault-tolerant
 - A **log** is a list of commands that are received and stored; this list is read sequentially and used as input by the state machine
 - Using a **consensus protocol**, each state machine processes the same list of commands in the log and thus produces the same series of results and arrives at the same series of states

SMR and Paxos

- Paxos is commonly applied to achieve SMR
 - The state machine commands and their sequencing (the order in which they appear) are the values to agree
 - But requires one instance of Paxos per command: many instances of Paxos are executed simultaneously!
- Multi-Paxos is a more efficient solution to reduce the number of messages
 - Why multi? Multiple rounds from a stable leader E' Leader UNICO.
 - Prepare phase only in first round, then only accept phase in next rounds
 - After the first round, the leader enters into a galloping mode where it sends successive accept messages when it receives a majority of acks for previous accept request
 - Galloping mode may be interrupted by leader crashing, in that case new leader must be elected

Other common use patterns of Paxos

- Log replication
 - To duplicate data across different nodes (different from SMR whose goal is to make copies of the server state)
- Synchronization service
 - To control concurrent access to shared data
- Configuration management
 - Leader election, group membership, service discovery, and metadata management

Vantaggi Paxos vs Algoritmi classici.

- Nella mutua esclusione, assumo non ci sia crash.
Con paxos, finchè c'è maggioranza di acceptors, posso lavorare anche con guasti.
- Partizione di rete: se in una c'è maggioranza di acceptor, l'algoritmo funziona.

Paxos in practice

- Some DSs that use Paxos
 - The first ones: Petal (distributed virtual disks) and Frangipani (scalable distributed file system)
 - Chubby: Google's distributed lock service used in BigTable, Google Analytics and other Google products
 - Zookeeper uses a Paxos-variant protocol called Zab
 - Spanner: Google's globally distributed NewSQL database
 - XtreemFS: fault-tolerant distributed file system for WANs
 - Mesos: uses Paxos to manage its replicated log
 - [LibPaxos](#): implementations for your app
- However, getting Paxos right in practice is hard
 - E.g., how to implement a globally unique proposal number
 - See [Paxos made live](#) paper by Google researchers

While Paxos can be described with a page of pseudo-code, our complete implementation contains several thousand lines of C++ code. The blow-up is not due simply to the fact that we used C++ instead of pseudo notation, nor because our code style may have been verbose. Converting the algorithm into a practical, production-ready system involved implementing many features and optimizations – some published in the literature and some not.

Algoritmo consenso

Raft



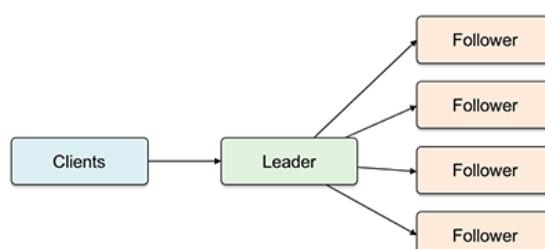
-
- Consensus algorithm developed in 2014 at Stanford University <https://raft.github.io>
 - RAFT: Replicated And Fault Tolerant
 - Goals:
 - Designed to be easier to understand, implement and validate than Paxos
 - Complete foundation for implementation
 - Paxos not complete enough for real implementations, the algorithm is specified in a way that is detached from real-world implementation issues and use cases
 - Paxos implementations need extensive proofs and verification of their own, detaching them further from the original theoretical results
 - Equivalent and as efficient as Paxos for log replication

Raft: features

- System model similar to Paxos' one
 - Delayed/lost messages, fail stop (not Byzantine)
- Equivalent to (multi-)Paxos in fault-tolerance and performance
- Differences from Paxos
 - Problem decomposed into relatively independent sub-problems (leader election and log replication)
 - Addresses all major pieces needed for practical systems
- Rapid and widespread adoption
 - Many implementations currently listed on [Raft home page](#), >10 versions in production
 - Some systems using Raft: etcd, CockroachDB, Consul, Hazelcast

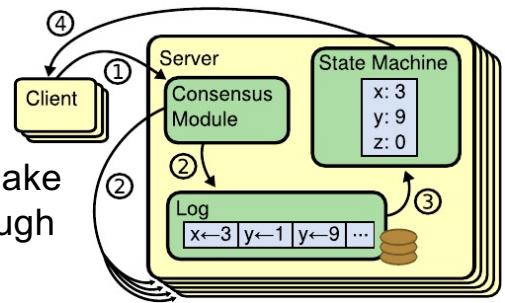
Raft: overview

- Raft is implemented on a **cluster of servers**, each of which hosts:
 - The **state machine** (provided service)
 - A **log** that contains inputs fed into the state machine
 - The **Raft protocol**
- One of the servers is *elected* to be the **leader**, the others function as **followers**
- Clients send commands only to the leader, who forwards them to followers
- Each of the servers stores received commands in a log



Raft: overview

- Raft is a *state machine replication* protocol
 - Each server has a *state machine* and a *log*: state machine is what we want to make fault-tolerant (e.g., key-value pairs) through replication
 - The state machine is a deterministic program that specifies the desired behavior of the cluster as a whole
 - The state machine processes a sequence of *commands*, given by external clients; they interact with the system as if it were a single node running a single copy of the state machine
 - Each server simulates a copy of the state machine
 - Protocol goal: to maintain consistency across the copies of the state machine by ensuring proper log replication



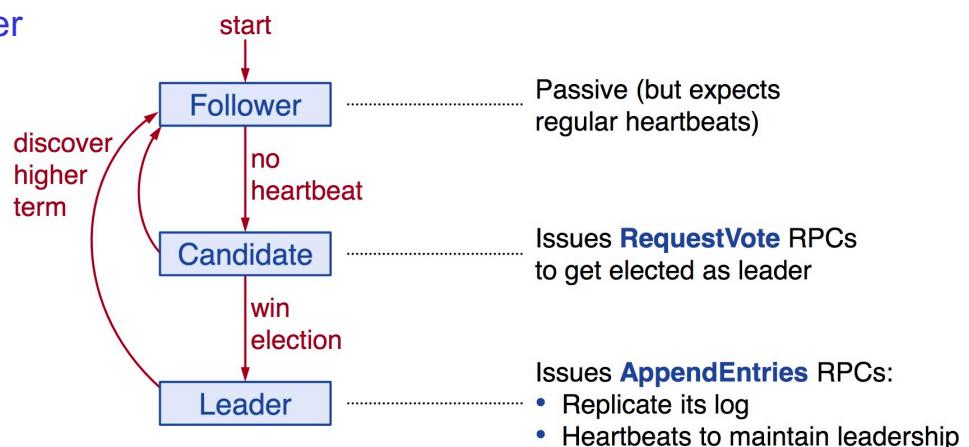
Raft: overview

- Two major components of Raft
- ## 1. Leader election
- Select one of the servers to act as **leader**
 - The leader is responsible for log replication to the followers
 - In case of leader crash, then choose new leader
- ## 2. Log replication (normal operation)
- Goal: make sure that replicated state machine is up to date across a majority of servers in the cluster
 - Leader accepts commands from clients, **appends** them to its log (note that **log is append-only**)
 - Leader replicates its log to other servers (overwriting inconsistencies)
- Let's examine Raft using
<http://thesecretlivesofdata.com/raft/>

Leader manda heartbeat verso follower. Se questo follower non riceve heartbeat, il follower può essere candidato, manda richieste di voto e se ottiene maggioranza di voti diventa nuovo leader. Essendo nuovo leader, dovrà mandare lui regolarmente heartbeat agli altri, per non perdere l'elezione.

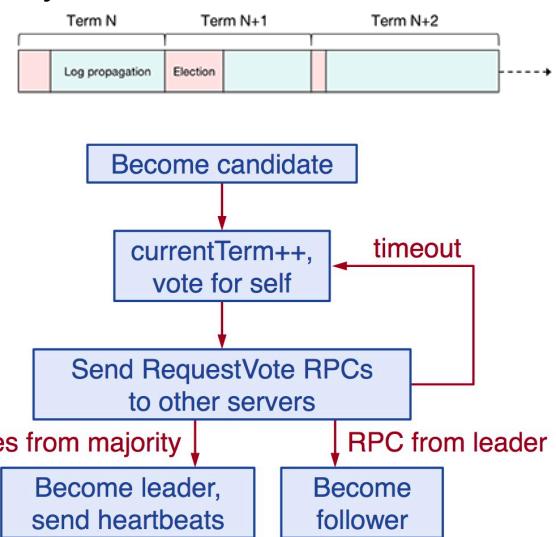
Raft: server state

- A server can be in 1 of 3 states:
 - Leader (at most one leader **per term**)
 - Candidate
 - Follower



Raft: leader election

- At most one leader per term
 - Some terms have no leader because of failed election (**split vote**)
- Each server maintains **currentTerm** value (no global view)
 - Each server has its own local view of time that is represented by its **currentTerm**; it increases monotonically over time
- Election timeout**
 - Follower waits until become candidate
- Election term starts if follower doesn't see a leader**
 - Candidate votes for self, and sends out **RequestVote** RPCs to all the other servers
 - Receiving servers vote on candidate iff they haven't voted yet this term
 - Election timeout reset



Raft: log replication

- Client sends command to leader
- Leader appends command to its log
- Leader sends *AppendEntries* RPCs to all followers in order to replicate all changes to all servers
 - *AppendEntries* message sent by leader to followers at periodic intervals specified by **heartbeat timeout**
 - Followers acknowledge *AppendEntries* message
 - Once the leader receives acks from a majority of servers, it executes the command on its state machine and returns result to client, and the log entry is considered *committed*

Raft: log replication

- Once new log entry is committed:
 - Leader notifies followers of committed entries in subsequent *AppendEntries* RPCs
 - Followers execute committed commands in their state machines
- Election term will continue until a follower stops receiving heartbeats and becomes a candidate

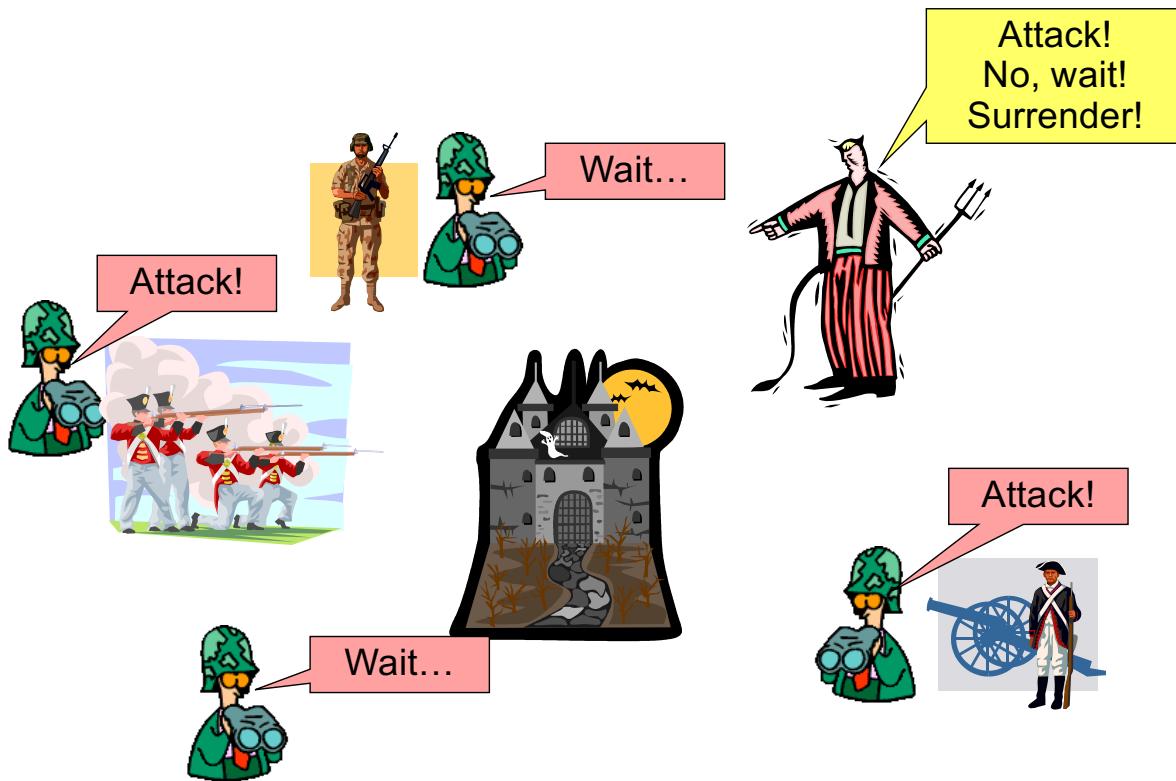
Raft: properties

- Raft guarantees **safety**
 - At most one leader per term
 - Logs are kept consistent
 - Only a node with an up-to-date log can become a leader
- Raft also provides a **liveness** guarantee
 - If there are “sufficiently few failures”, then the system will eventually process and respond to all client commands
- Raft is tolerant to **network partitions**
 - Log uncommitted so long as no majority
 - Majority as seen in face of partition, e.g. 2+3 partition
 - Recovery
 - Old leader steps down when sees higher term
 - Rolls backs uncommitted entries and matches new leader’s log

Raft: references

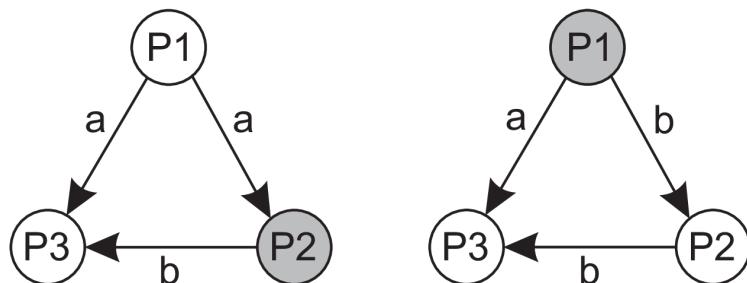
- See <https://raft.github.io>
 - The Raft paper: [In Search of an Understandable Consensus Algorithm](#) (Extended Version), 2014
 - Talk on Raft by John Ousterhout (Aug. 2016)
<https://youtu.be/vYp4LYbnnW8>
 - Another Raft visualization: <https://raft.github.io/raftscope/>

Byzantine scenario



Accordo in presenza di fallimenti bizantini

- In presenza di **fallimenti bizantini**, per sopravvivere ad attacchi di k processi guasti e raggiungere l'accordo distribuito occorre avere $N \geq 3k+1$ processi
 - E' il problema dei **generali bizantini** (definito da Lamport)
 - *Idea:* si vuole raggiungere l'accordo se attaccare una città oppure ritirarsi tra un gruppo di generali fedeli, essendoci k generali traditori \rightarrow occorrono $2k+1$ generali fedeli
 - Se non ci sono più dei $2/3$ di generali fedeli, non è possibile raggiungere l'accordo
 - P3 non riesce a capire chi sia il traditore tra P1 e P2

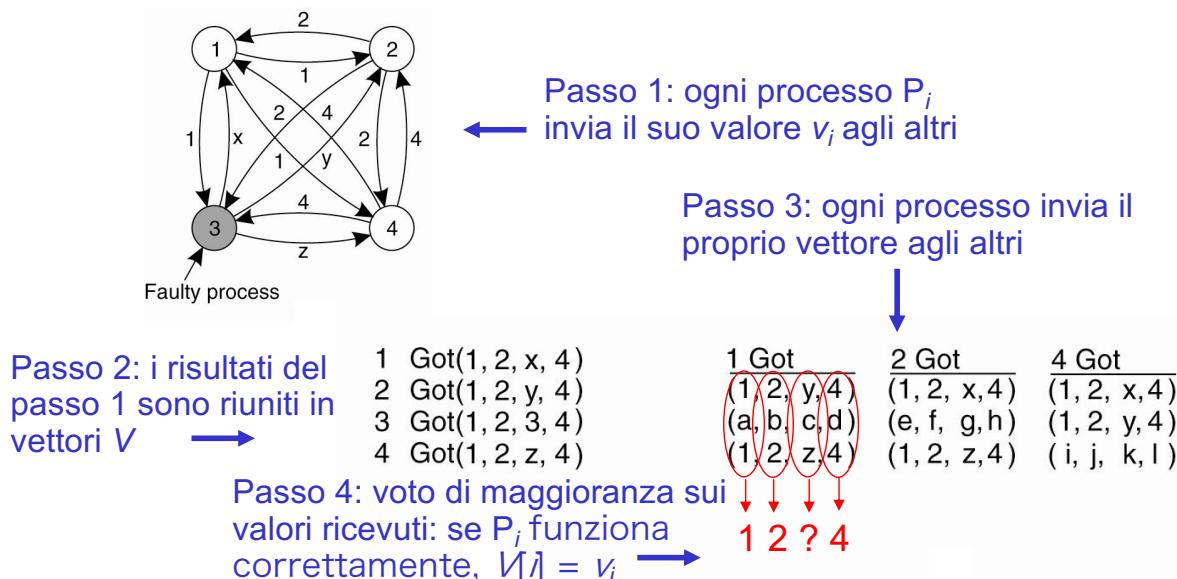


Problema dell'accordo bizantino

- Assunzioni:
 - processi sincroni
 - comunicazione unicast
 - ordinamento dei messaggi
 - ritardi limitati
- Ci sono N generali (ovvero processi) ed ogni processo i fornisce un valore v_i agli altri processi
 - v_i rappresenta la forza della truppa del generale i
- Obiettivo: far costruire ad ogni processo un vettore V di dimensione N tale che se il processo i è non guasto allora $V[i] = v_i$, altrimenti $V[i]$ è non definito

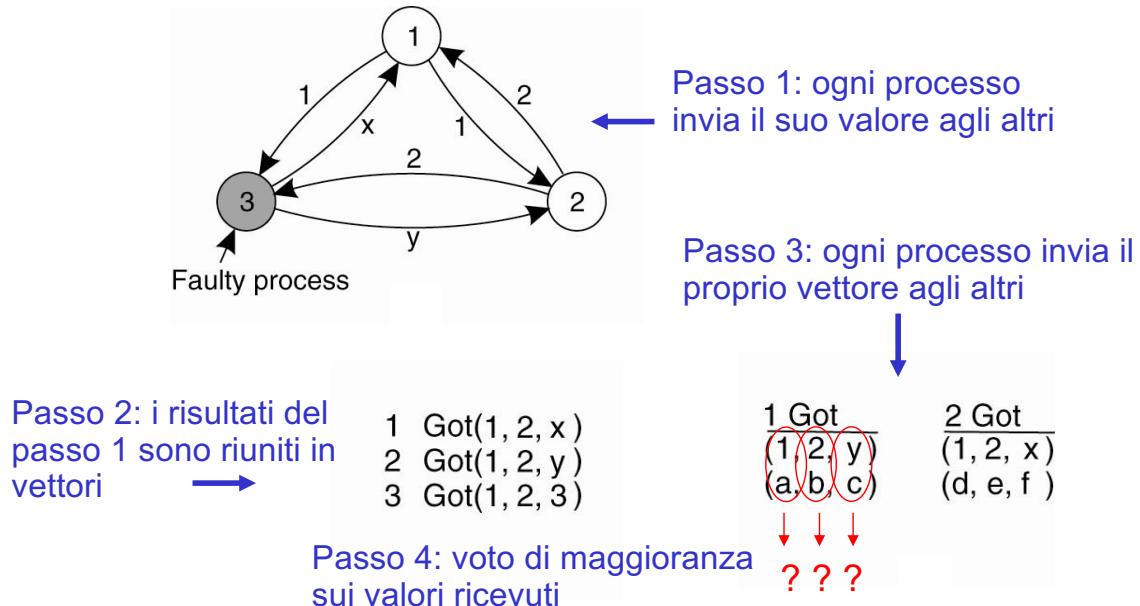
Problema dell'accordo bizantino

- Come raggiungere l'accordo nel caso di 3 processi che funzionano correttamente ed 1 fraudolento ($N=4$, $k=1$)?
 - Per semplicità assumiamo $v_i = i$



Problema dell'accordo bizantino

- Perché con 2 processi che funzionano correttamente ed 1 processo fraudolento ($N=3, k=1$) non si riesce a raggiungere l'accordo?



Lamport's algorithm for Byzantine agreement (oral message)

Algorithm OM(0)

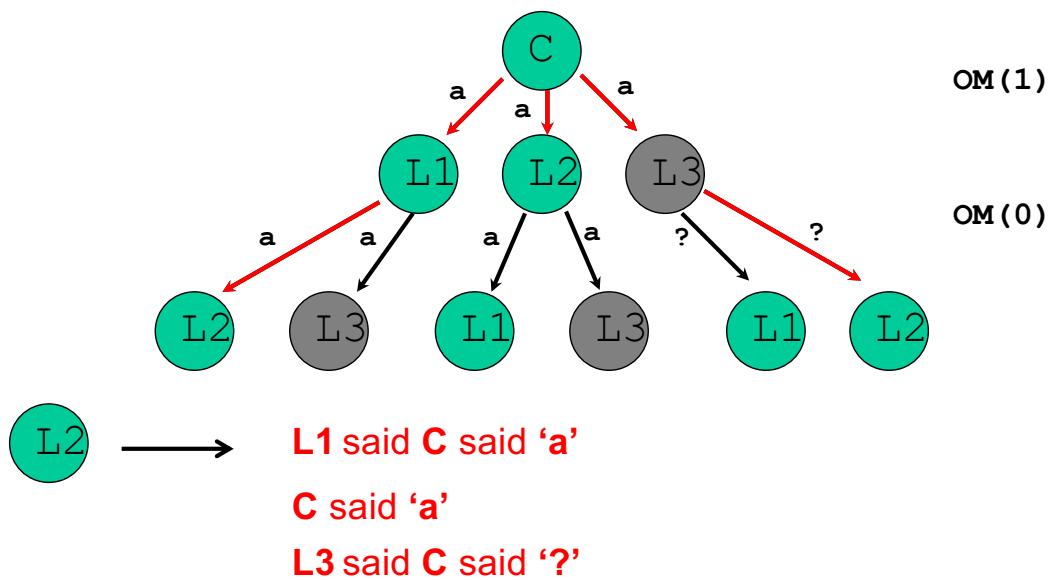
- The commander sends his value to every lieutenant
- Each lieutenant uses the value he receives from the commander, or uses the value RETREAT if he receives no value

Algorithm OM(k), $k > 0$

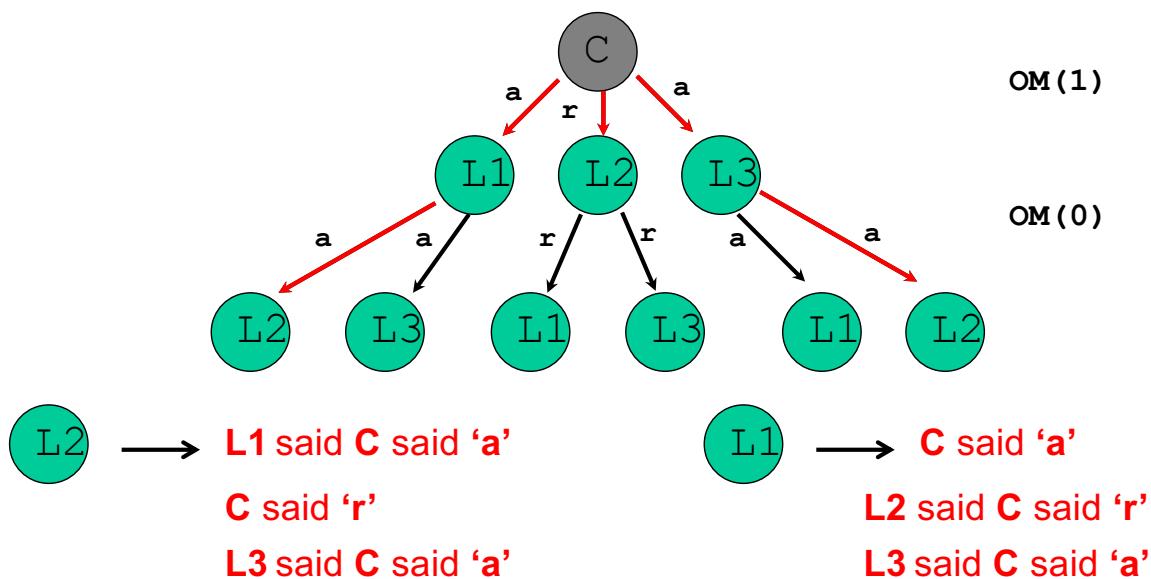
- The commander sends his value to every lieutenant
- For each i , let v_i be the value Lieutenant i receives from the commander, or else be RETREAT if he receives no value. Lieutenant i acts as the commander in Algorithm OM($k-1$) to send the value v_i to each of the $N-2$ other lieutenants
- For each i and each $j \neq i$, let v_j be the value Lieutenant i received from Lieutenant j in step 2 (using Algorithm OM($k-1$)), or else RETREAT if he received no such value. Lieutenant i uses the value majority(v_1, \dots, v_{N-1})

Lamport et al, [The Byzantine Generals Problem](#), ACM Transactions on Programming Languages and Systems, 1982

Demo: OM(1), L3 as traitor



Demo: OM(1), C as traitor



L2 result: majority(a, r, a) = a; L1 result: majority (a, r, a) = a

Byzantine fault tolerance in practice

- What about the performance of the algorithm for Byzantine generals problem?
 - Uses $k+1$ synchronous rounds: quite slow
 - Uses an exponential number of messages $O(N^k)$
- Byzantine fault tolerant protocols were long considered too expensive to be practical
- In 1999 the Practical Byzantine Fault Tolerance (PBFT) algorithm was proposed
 - Thousands of requests per second with only sub-millisecond increases in latency
 - PBFT triggered a renaissance in Byzantine fault tolerance research
- Bitcoin uses Byzantine fault tolerance