Hands-on Cloud Computing Services

Lezione 2

Gabriele Russo Russo

University of Rome Tor Vergata, Italy

3/11/2022

A.A. 2022/23

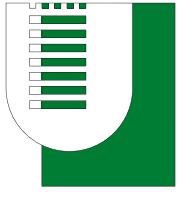

TOR VERGATA

UNIVERSITÀ DEGLI STUDI DI ROMA

Recap

Il nostro obiettivo è quello di istanziare un applicato (app photogallery) sfruttando i servizi AWS. Gli step da seguire sono:
1) istanziare la macchina virtuale nel portale AWS e collegarsi tramite protocollo ssh alla macchina.

- Amazon Web Services: regions, services, ...
- Elastic Compute Cloud (EC2)
  - Instance, AMI, Security Group
  - SSH, public/private keys
- Example web app: Photogallery

2)Trasferimento dell'applicativo .py sulla macchina, ovvero:
  2.1) installare python tramite il comando : sudo yum install python.
  2.2) installare flask tramite il comando: sudo pip3 install flask.
  2.3) trasferimento dell'applicativo.py tramite "scp".
3) L'applicativo funziona, ma è raggiungibile tramite un indirizzo IP. A livello di uso è necessario associarvi un dominio (photogallery.it invece che 12.3.4.200), ma questo è un servizio a pagamento di AWS di cui noi non usufruiremo.

Deploying Photogallery on EC2

4) L'applicativo funziona, ma non è nè scalabile nè fault tolerance (in pratica tutto fila liscio finchè lo usano poche persone, poi non starà dietro alle numerose richieste). Inoltre gira solo su una macchina, rotta/spenta quella, l'applicazione intera va giù.

Running Photogallery

```
$ export FLASK_APP=galleryApp.py
$ flask run -h 0.0.0.0 -p <numero di porta>
$ # Note: \-- requires root privileges for port 80
```

or, using the script `run.sh`:

```
$ bash run.sh
```

- Create a new EC2 instance to deploy the app
- Connect via SSH to the instance:

```
$ ssh -i <file.pem> ec2-user@<Public IP/Public DNS>
```

Deploying Photogallery on EC2 (contd.)

- Install the required software:

```
$ sudo yum install python3
$ sudo pip3 install flask
```

- Copy the app files from your PC using `scp`:

```
$ scp -i <chiaveprivata.pem> -r <cartellalocale> \
  ec2-user@<istanza ec2>:/home/ec2-user/
```

- Start the application:

```
$ cd photogallery/
$ bash run.sh
```

- Open `http://EC2-PUBLIC-IP/` in a browser
- Test: what if we “close” port 80 in the security group?

Replicating App Instances

- Current configuration is neither scalable or fault-tolerant
- Let's run multiple replicas of the web server
- We need a **load balancer**

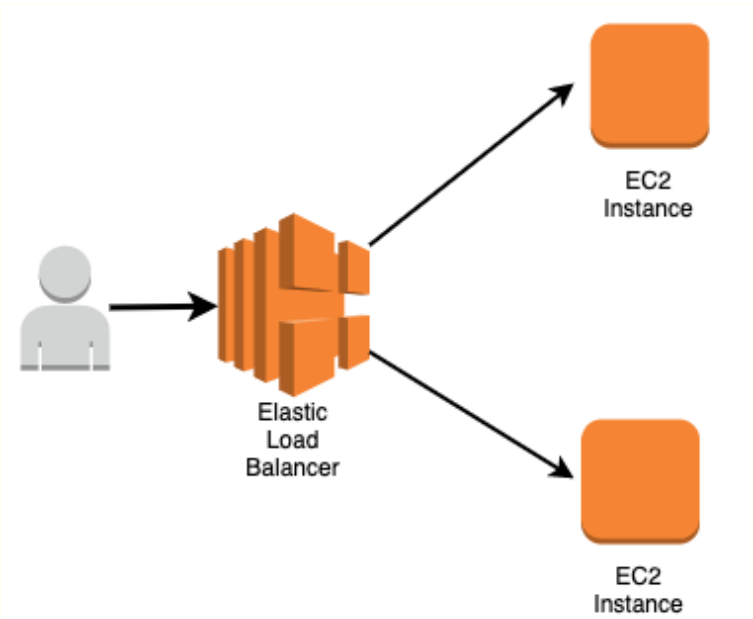

Il load balancer serve, nel momento in cui abbiamo più repliche della macchina, a reindirizzare le richieste ricevute. Elastic Balancer è il load balancer di amazon.

Preliminary Tasks

Il processo lo abbiamo inizializzato tramite shell. Quando chiudo sessione ssh chiudo anche il processo. Una buona soluzione per istanziare un processo è tramite l'istanzazione di un servizio. Utilizzeremo "systemmd".

- We run the app as a systemd **service**, automatically started at boot

/etc/systemd/system/photogallery.service

Creiamo un file photogallery.service così strutturato:

```
[Unit]
Description=Simple systemd service for Photogallery.

[Service]
Type=simple
WorkingDirectory=/home/ec2-user/photogallery
ExecStart=/bin/bash /home/ec2-user/photogallery/run.sh

[Install]
WantedBy=multi-user.target
```

Fatto ciò potremo avviare l'applicazione come un qualsiasi servizio systemd (volendo possiamo avviare il servzio della nostra app quando accendiamo la macchina!) Come??

Preliminary Tasks (contd.)

Starting and enabling the service

```
$ sudo systemctl daemon-reload
$ sudo systemctl start photogallery.service
$ sudo systemctl enable photogallery.service
```

Register an AMI

We also create an **AMI** using a snapshot of the running instance. We will be able to re-use the AMI to create new instances where the application is already installed and configured to start.

L' AMI è uno snapshot, usato quando riavvio l'istanza per riprendere dal precedente punto di sospensione.

Preliminary Tasks (contd.)

Come si usa?
Seleziono istanza EC2 -> "Crea immagine", lascio tutto di default e la creo. (la macchina verrà riavviata autonomamente). Creata l'immagine, creo una nuova istanza, spawnabile a partire da questa immagine. L'immagine è gratis, però la memorizzazione costa!
Quindi ha senso valutare la necessità di usare una AMI, anche perchè non è che ogni volta che aggiorno devo ritirare su tutte le VM.

Note: each AMI is associated with a snapshot of the root ELB volume attached to the instance. Keeping this snapshot has a (small) cost: `https://aws.amazon.com/premiumsupport/knowledge-center/ebs-snapshot-billing/`

Tutti i provider permettono di specificare dei dati di inizializzazione nel momento in cui si tira su una macchina. Tali USER DATA permettono di specificare un Bash script o direttive "cloud-init" (linguaggio per definire quello che la macchina deve fare ogni qual volta viene tirata su, es: quando vieni tirata su esegui comando A). Va specificato ogni qual volta creo una macchina, proprio per questo non lo useremo, ma cercheremo altri strumenti per automatizzare il processo!

Run Commands at Launch: cloud-init and User Data

- Creating a custom AMI allowed us to create new EC2 instances without manually configuring the application every time
- Any smarter approaches?
- Cloud providers allow you to run commands when instances are launched:
  `https://docs.aws.amazon.com/AWSEC2/latest/UserGuide/user-data.html`
- In AWS, you can use the User Data option to specify:
  - a Bash script
  - cloud-init directives
    (`https://cloudinit.readthedocs.io/en/latest/`)

Next step

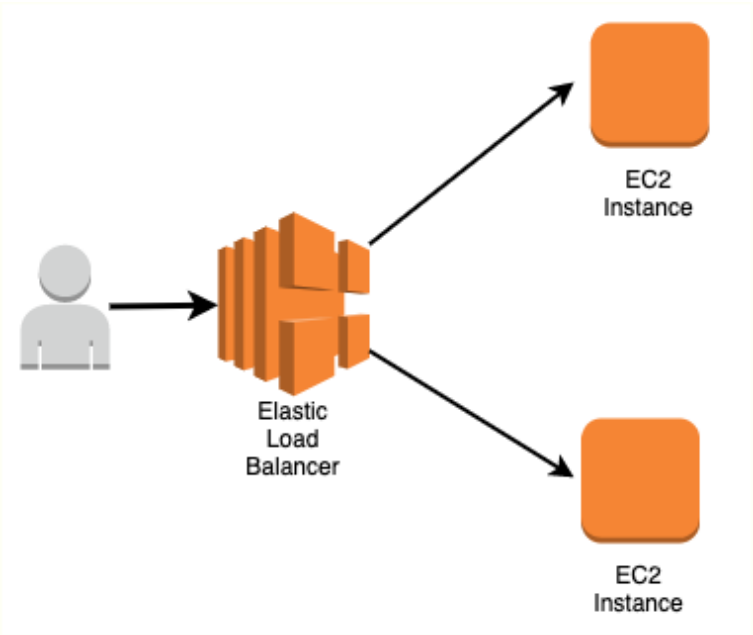

Amazon VPC

- Provision **logically isolated** sections of the AWS cloud
- Define virtual networks (IP ranges, subnets, gateways,...)
- May create a hardware Virtual Private Network (VPN) connection between your own datacenter and your VPC (**hybrid cloud**)
- **No additional charges** for creating and using the VPC itself.
- So far, we have used the default VPC

Amazon VPC: main building blocks

- In each AZ, we can define one or more **subnets**
- **Routing Tables** attached to subnets
- **Internet Gateway**

VPC Configuration: the hard way

- Create a new **Virtual Private Cloud (VPC)**
- We associate a block of (private) IP addresses to the VPC
  - Subnets will be created within this block of addressess
  - We can pick, e.g., `10.0.0.0/16`
- We can create **subnets**: each subnet is associated with an Availability Zone (AZ)
- Let's pick an AZ and create a subnet (e.g., `10.0.1.0/24`)
- If you want (for debugging), you can require that EC2 instances in the subnet are also assigned a public IP address
- Create an **Internet Gateway** (IG) to allow instances in the VPC to reach Internet; **associate** it with the VPC
- Create a **Route Table** for the VPC and **attach** it to the subnet(s)
- Add a new rule in the table: `0.0.0.0\0` – target: IG
- Repeat the above steps for each subnet you want.

VPC Configuration: the easy way

- AWS released a new UI to ease VPC configuration
- Most the elements you need automatically created along with the VPC
- You may only need to create an **Internet Gateway** (IG) to allow instances in the VPC to reach Internet and **associate** it with the VPC Add a new rule to the routing table(s): `0.0.0.0\0` – target: IG

Elastic Load Balancing (ELB)

- ELB automatically distributes incoming traffic across multiple targets (e.g., EC2 instances, containers, and IP addresses) in one or more Availability Zones
- It monitors the health of its registered targets and routes traffic only to the healthy targets
- 4 types of ELB:
  - Application Load Balancer (layer 5)
  - Network Load Balancer (layer 4)
  - Gateway Load Balancer (layer 3)
  - Classic Load Balancer (legacy)
- We'll use the Application LB today

ELB Configuration

- Create an ELB instance listening for HTTP requests on port 80
- Health check: use HTTP requests on port 80 with path /
- ELB needs a security group: configure one to accept traffic on port 80
- Create a few EC2 instances using our custom AMI in our subnets
- Register the instances to the ELB
- Wait a few minutes (DNS...) and then try to connect at the ELB URL with the browser

ELB Configuration

- Create an ELB instance listening for HTTP requests on port 80
- Health check: use HTTP requests on port 80 with path `/`
- ELB needs a security group: configure one to accept traffic on port 80
- Create a few EC2 instances using our custom AMI in our subnets
- Register the instances to the ELB
- Wait a few minutes (DNS...) and then try to connect at the ELB URL with the browser

Note:

- EC2 instances don't need a public IP address any more
- EC2 instances can now use a stricter security group:
  - Allowed source: `0.0.0.0/0` → `<ID of ELB sec group>`

Auto scaling

- We want to dynamically provision the number of active instances
- Let's use the Auto Scaling service of EC2

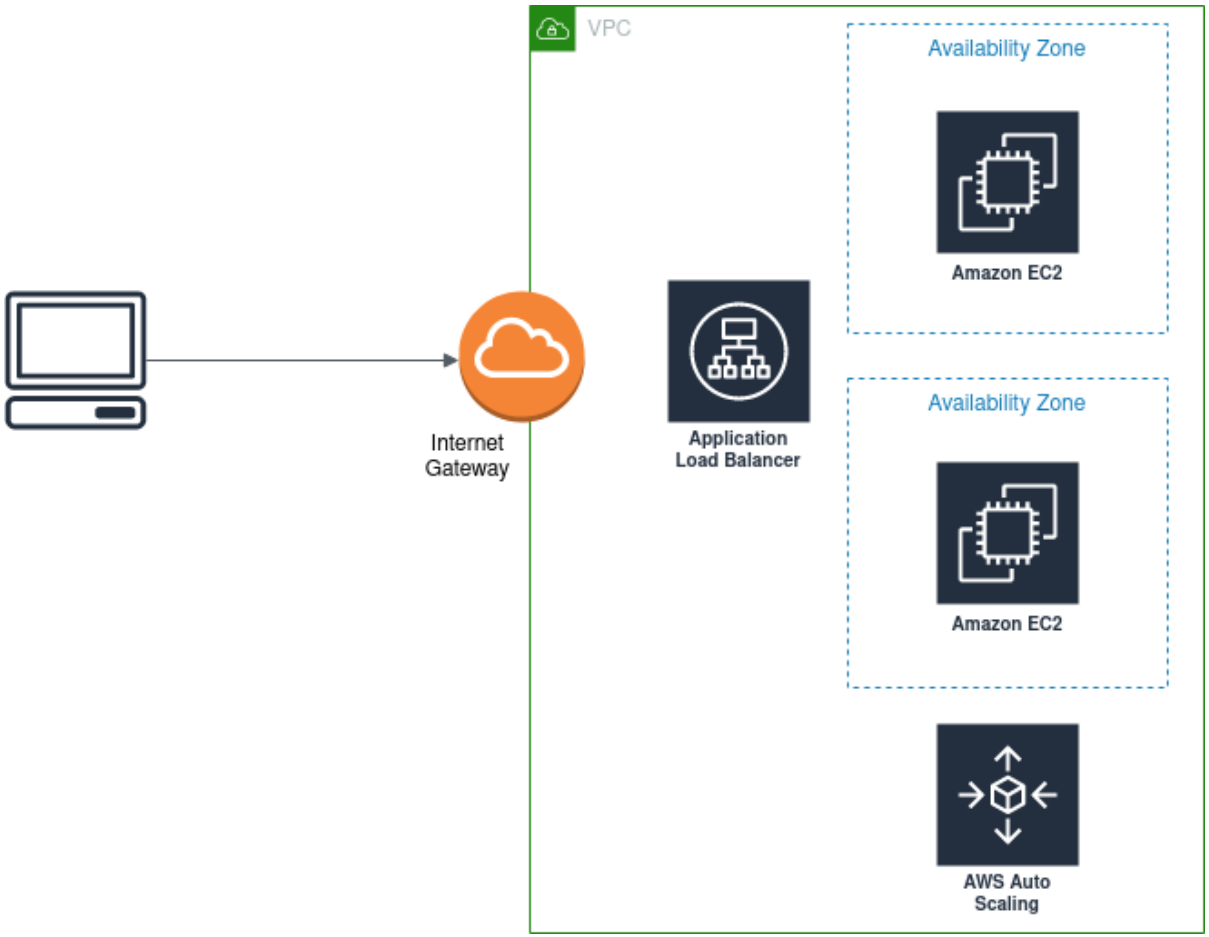

Auto Scaling + Photogallery

- Before starting, terminate manually launched instances
- Create a *Launch Template* for Photogallery
- Create an Auto Scaling Group that uses the new Launch Template
- Specify the VPC and the subnets where new instances should be launched
- Enable load balancing, associating the group with our ELB
- Set minimum and maximum number of instances (e.g., 2 and 5)
- Set an auto scaling policy
- Verify that new instances are automatically created