Performance Modeling of Computer Systems and Networks

Prof. Vittoria de Nitto Personè

Case study 1

A singol server queue

Università degli studi di Roma Tor Vergata
Department of Civil Engineering and Computer Science Engineering

1

Discrete-event simulation
Trace-driven simulation

Single server queue

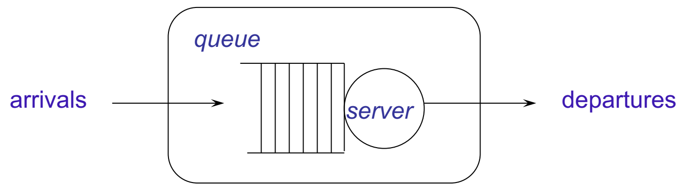

Consider n=10 job and given arrival and service times:

Arrival times:

15 47 71 111 123 152 166 226 310 320

Service times:

43 36 34 30 38 40 31 29 36 30

2

Discrete-event simulation
Trace-driven simulation

Algorithm 2: *trace-driven simulation*

$c_0 = 0.0;$ /* assumes that $a_0 = 0.0$ */
$i = 0;$
while (more jobs to process) {
  i++;
  a_i = GetArrival();
  if ($a_i < c_{i-1}$) $d_i = c_{i-1} - a_i$;
  else $d_i = 0.0$;
  s_i = GetService();
  $c_i = a_i + d_i + s_i$;
  }
  n = i ; conto i job presenti su questa traccia
return $d_1, d_2, \ldots, d_n$; restituisco delay degli 'n' jobs

Read data from a file

prendo istante arrivo
(la prima volta sarà falsa,
perchè c0 = 0 e a(i) > 0
Poi andando avanti, ci chiediamo
se il job che arriva può subito andare
nel server, o aspettare nel server node.

3

ssq1.c

```
#include <stdio.h>

#define FILENAME   "ssq1.dat"    /* input data file */
#define START      0.0

  double GetArrival(FILE *fp)   /* read an arrival time */
{   double a;
    fscanf(fp, "%lf", &a);
    return (a);}

double GetService(FILE *fp)   /* read a service time */
{   double s;
    fscanf(fp, "%lf\n", &s);
    return (s);}
```

versione C dello pseudocodice visto in precedenza.

4

```c
int main(void)
{  FILE   *fp;                    /* input data file */
   long   index     = 0;         /* job index */
   double arrival   = START;     /* arrival time*/
   double delay;                 /* delay in queue*/
   double service;                /* service time*/
   double wait;                   /* delay + service*/
   double departure = START;      /* departure time*/
   struct {                       /* sum of ...   */
       double delay;      /*delay times */
       double wait;       /*wait times*/
       double service;    /*service times */
       double interarrival; /*   interarrival times */
   } sum = {0.0, 0.0, 0.0};
```

index = i = conto numero di job

struttura dati per le statistiche


```c
fp = fopen(FILENAME, "r");
if (fp == NULL) {
   fprintf(stderr,"Cannot open input file %s\n",FILENAME);
   return (1);  }
while (!feof(fp)) {
   index++;
   arrival      = GetArrival(fp);
   if (arrival < departure)
       delay   = departure - arrival; /* delay in queue   */
   else  delay       = 0.0;           /* no delay   */
   service = GetService(fp);
   wait   = delay + service;
   departure     = arrival + wait;   /* time of departure */
   sum.delay    += delay;
   sum.wait     += wait;
   sum.service += service;   }
```

```
sum.interarrival = arrival - START;

printf("\nfor %ld jobs\n", index);
printf("average interarrival time = %6.2f\n", sum.interarrival / index);
printf("   average service time .... = %6.2f\n", sum.service / index);
printf("   average delay .......... = %6.2f\n", sum.delay / index);
printf("   average wait ........... = %6.2f\n", sum.wait / index);

fclose(fp);
return (0);}
```


7

Sui 10 job in esempio trovo questo: in blu ciò che ho letto da file, in rosso ciò che è stato calcolato.

	i	1	2	3	4	5	6	7	8	9	10
read from file	a_i	15	47	71	111	123	152	166	226	310	320
from algorithm	d_i	0	11	23	17	35	44	70	41	0	26
read from file	s_i	43	36	34	30	38	40	31	29	36	30

- average interarrival time $\bar{r} = \frac{a_n}{n} = \frac{320}{10} = 32.0$ sec
- average service time $\bar{s} = 34.7$ sec
- arrival rate $\frac{1}{\bar{r}} \approx 0.031$ job/sec
- service rate $\frac{1}{\bar{s}} \approx 0.029$ job/sec

nel tempo job si accumulano in coda, che tende ad infinito. Questo perchè service rate > arrival rate

- traffic intensity $\frac{\bar{s}}{\bar{r}} = 1.084375$
- utilization $\bar{x} = \frac{n}{c_n}\bar{s} = 0.92287$

è alta, normalmente già al 70% è elevato, perchè poi devo considerare momenti di picco etc

Insight: The server is not quite able to process jobs at the rate they arrive on average.

8

	i	1	2	3	4	5	6	7	8	9	10
read from file	a_i	15	47	71	111	123	152	166	226	310	320
from algorithm	d_i	0	11	23	17	35	44	70	41	0	26
read from file	s_i	43	36	34	30	38	40	31	29	36	30
completion time		58	94	128	158	196	236	267	296	346	376

Job-averaged statistics

- average delay and service time $\bar{d} = 26.7$, $\bar{s} = 34.7$ sec
  therefore, the average wait time is:

$$\bar{w} = \bar{d} + \bar{s} = 26.7 + 34.7 = 61.4 \text{ sec}$$

- verification is a difficult step

↓

Consistency check:
used to verify that a simulation satisfies known equations

- compute $\bar{w}, \bar{d}, \bar{s}$ *independently*
- then verify that $\bar{w} = \bar{d} + \bar{s}$

$$\bar{l} = \frac{1}{\tau}\int_0^\tau l(t)dt \qquad \bar{q} = \frac{1}{\tau}\int_0^\tau q(t)dt \qquad \bar{x} = \frac{1}{\tau}\int_0^\tau x(t)dt$$

With $\tau = c_{10} = 376$

$$\bar{l} = \frac{n}{c_n}\bar{w} \qquad \bar{l} = \frac{10}{376}61.4 = 1.633 \qquad \bar{q} = 0.710 \qquad \bar{x} = 0.923$$

popolazione nel centro, in media

The average of numerous random observations (samples) of the number in the service node should be close to $\bar{l}$.

(Same holds for $\bar{q}, \bar{x}$)

Relazioni tra variabilità, prestazioni, discipline di scheduling e distribuzioni di probabilità

Service times:

		media	varianza	response time
43 36 34 30 38 40 31 29 36 30		34.7	20.21	26.70

+20 -20

sommo + 20, - 20, + 20 etc, ad ogni valore, la media non cambia ovviamente.

impatto scheduling, usando i dati presi da "alta variabilità" li ordino, prima in modo crescente, poi in modo decrescente.

		media	varianza	response time
63 16 54 10 18 60 51 9 56 10	*alta variabilità*	34.7	504.21	32.7
9 10 10 16 18 51 54 56 60 63	*fair*	34.7	504.21	12.8
63 60 56 54 51 18 16 10 10 9	*unfair*	34.7	504.21	77.7

L'osservazione importante da fare è che LO SCHEDULING NON HA UN COSTO, quindi la sua implementazione, che può migliorare le prestazioni se ben applicato, non ha impatti sui costi, come può essere il potenziamento di una CPU.

Il programma in C visto primo stamperebbe questo.

Dati originari

for 10 jobs
average interarrival time = 32.00
average service time .... = 34.70
average delay .... = 26.70
average wait .... = 61.40

$$\bar{l} = \frac{10}{376} 61.4 = 1.633$$

Dati con alta variabilità

for 10 jobs
average interarrival time = 32.00
average service time .... = 34.70
average delay .... = 32.70
average wait .... = 67.40

$$\bar{l} = \frac{10}{376} 67.4 = 1.793$$

Ordinamento unfair

for 10 jobs
average interarrival time = 32.00
average service time .... = 34.70
average delay .... = 77.70
average wait .... = 112.40

$$\bar{l} = \frac{10}{376} 112.4 = 2.989$$

popolazione media è quasi raddoppiata

Ordinamento fair

for 10 jobs
average interarrival time = 32.00
average service time .... = 34.70
average delay .... = 12.80
average wait .... = 47.50

$$\bar{l} = \frac{10}{376} 47.50 = 1.263$$

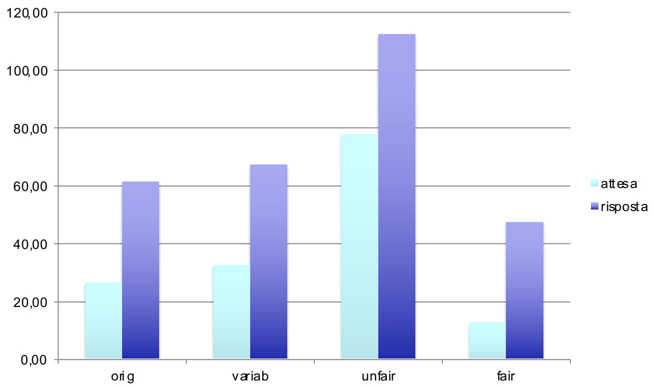

Applichiamo questo caso, del servente singolo, ad un case study:

Case Study

- The owners of an ice cream shop are considering adding additional flavors and cone options (aumentano gusti e combinazioni di gelati)
- But they are concerned about the effect of the resultant increase in service times on queue length (questo impatta sui tempi di servizio)

The case can be studied as a single-server queue

1000 istanti di arrivo al centro

- ssq1.dat represents 1000 customer interactions at the shop (arrival times and the corresponding service times)
- for the study, the service times are sistematically increased (and decreased) by a common multiplicative factor

Prima abbiamo visto "dal problema al modello", ora stiamo vedendo come "progettare gli esperimenti". Qui si aumenta e si decrementa, dalla traccia, il tempo di servizio, per creare una "curva".

Exercise 1

By running ssq1 for the datafile ssq1.dat, the following can be observed:

Observed arrival rate $\frac{1}{\bar{r}} \approx 0.10$ job/sec

Observed service rate $\frac{1}{\bar{s}} \approx 0.14$ job/sec

il sistema riesce a gestire il flusso.

- Modify the program to compute $\bar{l}, \bar{q}, \bar{x}$

utilizzazione $\bar{x}$ = 72%
per il 28% è libero

- You will find $1 - \bar{x} \approx 0.28$

Despite this significant idle time (28%), enough jobs are delayed so that the average number in the queue is

$\bar{q} \approx 2$

numero medio nella coda, per un sistema che è nel 28% del tempo libero.

Discrete-event simulation
ssq - case study

15% ↑ service times   109% ↑ queue length

30% ↑ service times   518% ↑ queue length

popolazione nella coda

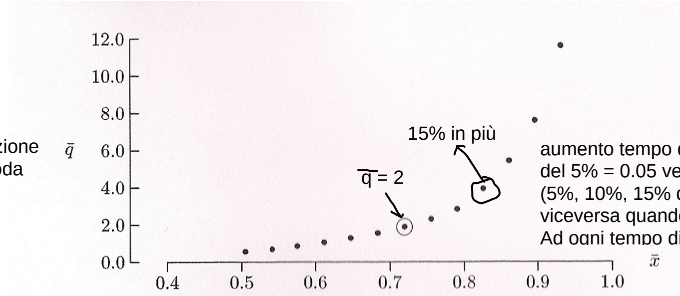

aumento tempo di servizio del 5% = 0.05 verso l'alto (5%, 10%, 15% quando salgo, viceversa quando scendo).
Ad ogni tempo di servizio moltiplico di 1.05, per avere aumento 5%

- even a modest increase in service times will produce a significant increase in the average queue length
- nonlinear relationsheep between $\bar{q}, \bar{x}$ particularly pronounced when utilization approaches 1

Superato il 70% dell'utilizzazione, il sistema degrada le prestazioni. Infatti diventa esponenziale, prima si comporta in modo più lineare. Per questo si cerca di avere utilizzazione sotto al 70%

Discrete-event simulation
ssq - case study

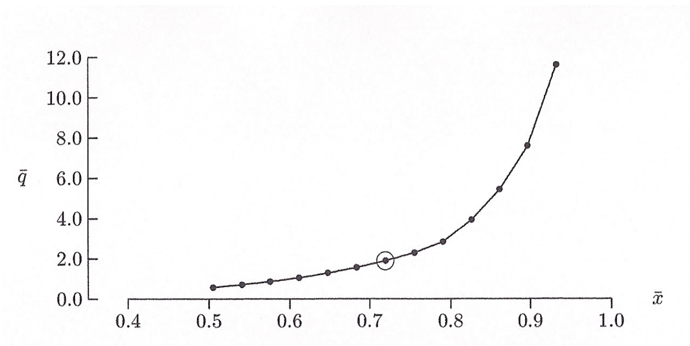

- $\bar{q}, \bar{x}$ are continuous in the values → many additional points more
- few would question the validity of “connetting the dots”

Ha senso "unire i puntini"? Se le grandezze sono continue (come il caso delle popolazioni medie) può aver senso unire i punti. Se i punti sono pochi, e la variabilità è molto bassa, può aver senso collegarli. Se la variabilità è alta, allora devo calcolare più punti, perchè non posso dire con certezza cosa avviene nei punti.

Guidelines

(no incertezza)

- If the data have essentially no uncertainty and the resulting is smooth OK connecting the dots, but the original are left
- If the data have essentially no uncertainty but the resulting is not smooth more dots need to be generated
- If the dots correspond to ucertain data, NO interpolation! (approximation)
- If the data is inherently discrete, NEVER interpolation!

Se i dati sono discreti, non ha senso interpolare. MAI.

Exercises

- Ex 1.1.2 and Ex 1.1.3 on p.11 from textbook
- Study the program ssq1.c
- Run with ssq1.dat; analyze the results
- Generate a data file with the values on p.8
- Run with the new data, verify that the results confirm the expectations
- Ex 1.2.2 and Ex 1.2.3 on p.24 of the textbook