

Performance Modeling of Computer Systems and Networks

Prof. Vittoria de Nitto Personè

Operational analysis:
Queueing Networks

Università degli studi di Roma Tor Vergata
Department of Civil Engineering and Computer Science Engineering

Copyright © Vittoria de Nitto Personè, 2021
<https://creativecommons.org/licenses/by-nc-nd/4.0/>



1

Da un punto di vista degli analisti di sistema si è creato dello scetticismo, perché il modello era regolamentato da un approccio stazionario, le ipotesi richiedevano indipendenza stocastica tra i job, etc...

Analytical models
conceptual model

Analytical models

Queueing network (QN) modelling is a particular approach to computer system (CS) modeling in which the CS is represented as a *network of queues* which is evaluated *analytically*

- Many analysts experienced doubts on its accuracy
- A series of assumptions:
 - ✓ the system is modeled by a *stationary stochastic process*;
 - ✓ jobs are *stochastically independent*;
 - ✓ job steps from device to device follow a *Markov chain*;
 - ✓ the system is in stochastic equilibrium;
 - ✓ the service time requirements at each device conform to an *exponential distribution*;
 - ✓ the system is *ergodic*, i.e. long-term time averages converge to the values computed for stochastic equilibrium

Prof. Vittoria de Nitto Personè

2

2

Molte assunzioni erano "forzate" rispetto al caso in analisi.

Analytical models

Some of these concepts are difficult and **cannot be proved to hold by observing the system in a finite time period**
Most can be disproved empirically

- ✓ parameters change over time
- ✓ jobs are dependent
- ✓ systems are observable only for short periods
- ✓ ...

Analytical models

In applying or validating the results of Markovian QN theory, **analysts substituted operational values for stochastic parameters**

directly measured

The Markovian QN equations are also valid among operational variables

They hold under different assumptions and **apply to a large class of real systems**¹

¹ BUZEN, J.P. "Operational analysis: the key to the new generation of performance prediction tools," in Proc. IEEE COMPCON, 1976, IEEE, New York.
DENNING, P. J.; AND BUZEN, J. P. "Operational analysis of queueing networks," in Proc. Third Int. Symp. Computer Performance Modeling, Measurement, and Evaluation, 1977, North-Holland Publ. Co., Amsterdam, The Netherlands.

Operational Analysis

Operational Analysis

Three **operational principles**:

1. All quantities should be *precisely measurable* and all assumptions should be *directly testable*
2. The system must be *flow balanced*
3. The devices must be *homogeneous*,
i.e., the routing must be independent of queue lengths (q_i)
the mean service time at a given device must not depend on q_i of other devices

the same mathematical equations

but the operational assumptions can be tested

↓

much more confidence and understanding of the QN technology

Prof. Vittoria de Nitto Personè 5

5

Una ipotesi è testabile operazionalmente se può essere misurata da misure sul sistema

Analytical models
Operational analysis

Operational Analysis

Def.
Hypotheses whose veracity can be established beyond doubt by measurement will be called *operationally testable*

Operational analysis provides a rigorous mathematical discipline for studying CS performance based solely on operationally testable hypotheses

two basic components:

- a system (real or hypothetical)
- a (finite) time period

↘ the observation period

Prof. Vittoria de Nitto Personè 6

6

Le componenti sono il sistema su cui faccio le misure, e un intervallo di osservazione per il sistema.

Analytical models
Operational analysis

Operational Analysis

According to the *operational* approach, let us consider

Basic quantities

T	the length of the observation period (op)
A	the number of arrivals during op
B	the total amount of time during which the system is busy $B \leq T$ during op
C	the number of completions during op

A/T = frequenza di arrivo, cioè λ
 C/T = frequenza di uscita, cioè X (ma per ora non lo chiamiamo throughput)
 B/T = utilizzazione U
 B/C = servizio medio S

Prof. Vittoria de Nitto Personè 7

7 Osserviamo che: $U = C/C * B/T = C/T * B/C = X * S$, legge dell'utilizzazione.
 Non ho fatto nessuna assunzione di equilibrio tra flussi, possiamo infatti derivare l'utilizzazione per una certa finestra, senza bisogno dell'equilibrio.
 E' valida per ogni finestra temporale. Ma cosa vuol dire bilanciamento dei flussi?
 Sarebbe $A=C$, tutto ciò che arriva è uguale a ciò che esce nella stessa finestra temporale T .
 Essa è una condizione facilmente testabile.
 Tale assunzione è detta "job flow balance", allora $A/T=C/T$, allora $\lambda = X$, ovvero solo sotto condizione di job balance. Allora l'utilizzazione è scrivibile come
 $U = \lambda * S$, probabilità che ad un certo istante di tempo il sistema sia occupato.

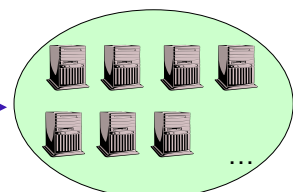
Non è detto che il JFB valga per ogni finestra temporale, tuttavia si può fare sempre questa assunzione, senza particolari errori. Esso è valutabile con $(A-C)/C$, se $A=C$ ovviamente ho errore 0, e cresce se A si discosta da C .

Estensione su più centri

Multi Resources Systems 1

- a collection of servers, working together for incoming requests
- homogeneous servers

requests →



Data centers
Server farm


What is the minimum number of servers needed to guarantee that only a small fraction of jobs are delayed?

Is a single central queue superior to having a queue at each server?

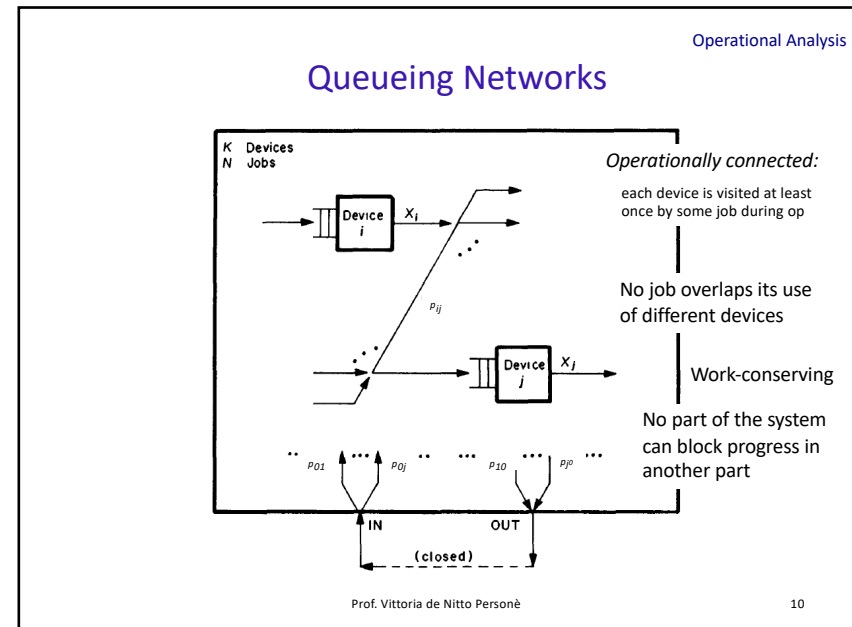
Prof. Vittoria de Nitto Personè 8

Nel modello operativo abbiamo la seguente rappresentazione, se il sistema è chiuso dobbiamo scegliere un punto particolare (come un arco). Non deve esserci sovrapposizione di job su devices diversi (no uso simultaneo). I dispositivi sono work conserving, quindi se c'è un job da servire lo si serve (non sta idle). Non c'è blocco, ovvero un dispositivo non può bloccare il progresso di altre parti. C'è sempre posto (equivale al concetto di code infinite, ma questo è uno scenario diverso comunque!)

modello a code



9



10

Operational Analysis

Queueing Networks

K Devices
 N Jobs

Device i X_i

Device j X_j

$N = n_1 + n_2 + \dots + n_K$
nei singoli device

p_{ij} are called the "routing frequencies"

non si parla di probabilità

X_0 the system output rate, the number of jobs per second leaving the system

se < 1 coincide con throughput

Prof. Vittoria de Nitto Personè

11

11

Operational Analysis

Queueing Networks

K Devices
 N Jobs

Device i X_i

Device j X_j

X_0 è quello che arriva (tasso arrivo),
 N varia perchè sistema aperto
If the system is *open*, X_0 is known and N varies as jobs enter or leave the system

An analysis of an open system assumes that X_0 is known and seeks to **characterize the distribution of N** devo caratterizzarla, perchè N varia.

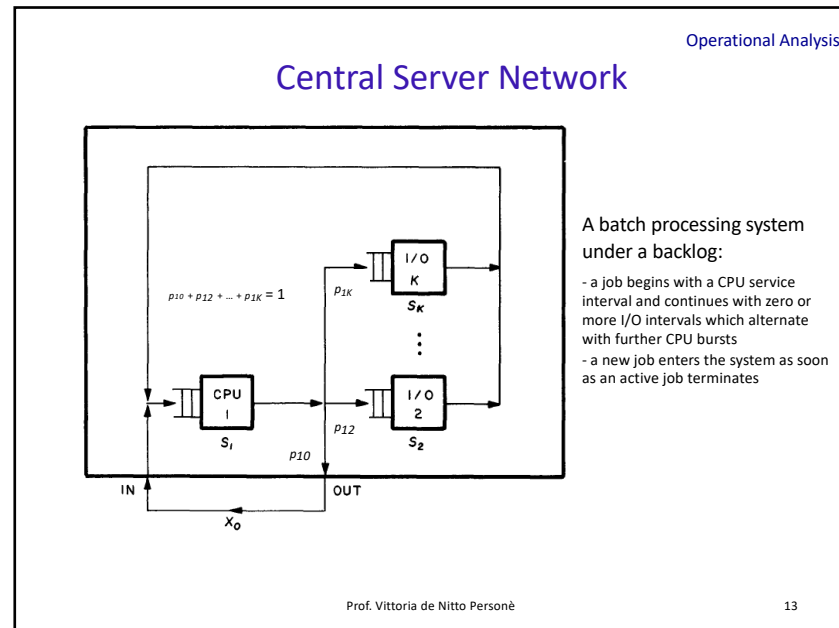
If the system is *closed* the number of jobs N is fixed
An analysis of a closed system begins with N given and seeks to determine the resulting X_0 along the OUT/IN path

Queue lengths and response times at the devices may be sought in both cases

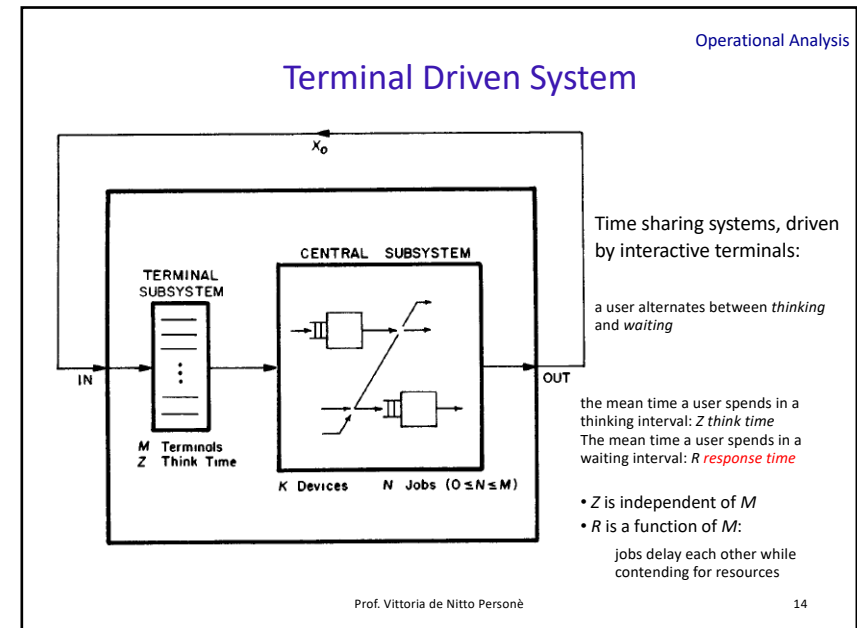
Prof. Vittoria de Nitto Personè

12

12 Riprende MVA ricorsivo, anche lui parte da N .



13



14

Sistema Terminal Driven, c'è un sottosistema che include tutti i terminali (sulla sinistra), e un sistema centrale (sulla destra). *M* sono i terminali connessi, *Z* è il tempo in cui l'utente "pensa", da non confondere con il tempo in cui l'utente lancia il comando e rimane in "attesa" della risposta. Il tempo medio in "attesa" corrisponde al tempo medio di passaggio nel "central subsystem", cioè Response Time *R*. Esso è in funzione di "*M*", quante più richieste vengono lanciate, più il sistema sarà carico. *N* varia nel tempo, va da 0 a *M* (tutti gli utenti aspettano risposta, carico massimo).

già viste

Operational analysis

Queueing Networks

The system is measured for an op of T seconds, the following data are collected for each device $i=1, 2, \dots, K$

- A_i the number of arrivals;
- B_i total busy time, during which $n_i > 0$
- C_{ij} number of times a job requests service at device j immediately after completing a service request at device i ;
note that it is possible $C_{ii} > 0$.


If we treat the “outside world” as device “0”, we can define also

- A_{0j} number of jobs whose first service request is for device j ;
- C_{i0} number of jobs whose last service request is for device i .

Prof. Vittoria de Nitto Personè

15

15



16

Operational Equations

$$X_j = \sum_{i=0}^K X_i p_{ij}$$

passo a loro moltiplicando
per X_0 ad entrambi

$$\begin{cases} V_0 = 1 \\ V_j = p_{0j} + \sum_{i=1}^K V_i p_{ij} \end{cases}$$

portato fuori (V_0 è 1)

Job Flow Balance equations

altrimenti le code crescono,
e diventa tutto confusionario.

sistema ad unica soluzione
Visit Ratio equations

La prima formula viene dai completamenti divisi per il tempo di osservazione.

La legge del flusso forzato è: $X_i = V_i X_0$, cioè il flusso totale del sistema
per il numero medio di visite ci da la parte del singolo X_i .

Prof. Vittoria de Nitto Personè

17

- 17 Se sistema è chiuso, devo scegliere un punto fisso.
 $V(i/j) = Y_i/Y_j$ quante volte in media visito "i" per un passaggio a "j".

Operational Equations

$$U_i = X_i S_i \quad \text{Utilization Law}$$

$$\bar{n}_i = X_i R_i \quad \text{Little's Law}$$

$$X_0 = \sum_{i=0}^K X_i p_{i0} \quad \text{Output Flow Law}$$

$$R = \sum_{i=1}^K V_i R_i \quad \text{General Response Time Law}$$

$$R = M/X_0 - Z \quad \text{Interactive Response Time Formula (Assumes flow balance)}$$

da esaminare


Prof. Vittoria de Nitto Personè

18

- 18 legge generale del tempo di risposta ritrovata operazionalmente

$R_{\text{medio}} = N_{\text{medio}}/X_0 = \sum_{i=1}^k (n(i))/X_0$, perchè $N_{\text{medio}} = n_1 \text{ medio} + n_2 \text{ medio} + \dots$
se applico Little: $\sum_{i=1}^k R_i [X_i / X_0] = \sum_{i=1}^k R_i [V_i]$

Per il sistema INTERATTIVO



il tempo $(Z + R)X_0 = M$ per Little, applicato a tutto.

L'interactive response time, per un sistema di questo tipo è:
 $R = M/X_0 - Z$, dalla formula precedente.

Questo sistema serve una parte di carico "aperta", e poi c'è un insieme di terminali fissati.

C'è il carico interattivo (lancio richiesta - aspetto risposte) e carico batch.

